

Bachelorarbeit

Räumliche Analyse von Feinstaubmessungen

Autor

Bruce Wayne

Betreuer

Prof. Dr. Ludwig Fahrmeir
Institut für Statistik



Institut für Statistik
Ludwig-Maximilians-Universität München
München, 30. Juli 2026

Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation	1
1.2	Gliederung dieser Arbeit	3
2	Theoretische Grundlagen	4
2.1	Grundidee des Kriging	4
2.2	Grundlegende Begriffe	5
2.3	Semivarianz und Variogramm	7
2.3.1	Schätzung der empirischen Semivarianz	8
2.4	Kovarianz-Funktionen	10
2.4.1	Nugget Effekt	14
2.4.2	Übersicht der eingeführten Fachbegriffe	15
2.5	Kriging-Gleichungen	16
2.5.1	Methodik des Kriging	16
2.5.2	Simple Kriging	17
2.5.3	Ordinary Kriging	18
2.5.4	Universal Kriging	18
2.5.5	Zusammenfassender Überblick	19
2.6	Anisotropie	20
3	Analyse der Feinstaubdaten	24
3.1	Feinstaub: Definition, Entstehung und Bedeutung für die Gesundheit . . .	24
3.2	Herkunft und Qualität der Daten	26
3.3	Struktur der Daten	29
3.4	Datenbereinigung	31
4	Datenauswertung	34
4.0.1	Kriging Interpolation mit anisotropen Kovarianz-Modellen	34
4.1	Verwandte Arbeiten	38
5	Diskussion und Ausblick	40
A	Anhang	LI
A.1	Weitere Kovarianz-Funktionen	LI
A.2	Ergänzende Analysen der Datenauswertung	LV
A.3	Unterstützung durch Künstliche Intelligenz	LVI
B	Elektronischer Anhang	LVII
C	Literaturverzeichnis	LVIII

1 Einleitung

1.1 Motivation

Aufgrund ihrer erdgeschichtlichen Genese kommen industriell nachgefragte und daher wirtschaftlich bedeutsame Rohstoffe nur heterogen verteilt vor und lagern meist in einigen Hundert Metern Tiefe in den oberen Schichten der Erdkruste.

So liegt beispielsweise der Goldanteil an der Erdkruste nach Haynes 2017 bei $4 \cdot 10^{-3} \text{ mg/kg}$, das heißt, es müssen 1000 Tonnen Gestein gefördert, zerkleinert und chemisch aufgearbeitet werden, um 4 Gramm Gold zu gewinnen.

Ein Abbau steht somit unter dem Vorbehalt der Wirtschaftlichkeit, weshalb möglichst gute Vorhersagen des zu erwartenden Goldertrags basierend auf Stichproben durch Probebohrungen erforderlich sind.

Einer der ersten Wissenschaftler, der sich den aus dieser Abwägung entstehenden Fragestellungen annahm, war der Bergbau-Ingenieur Danie G. Krige (vgl. Krige 1951).

Die Idee des von dem Geologen und Mathematiker G. Matheron (vgl. Matheron 1963) in Anerkennung der Vorarbeiten von Krige als „Kriging“ bezeichneten Prognoseverfahrens fußt auf der empirisch gut begründeten Annahme, dass eine Beobachtung $Z(s)$ an einem Ort s umso mehr Ähnlichkeit zu einer benachbarten Beobachtung $Z(s')$ an einem Ort s' aufweist, je geringer die Entfernung $\|s - s'\|$ zwischen den beiden Orten ist.

Beispielsweise gelten die folgenden Heuristiken:

- Bei der Suche nach Walderdbeeren stellt es eine erfolgversprechende Strategie dar, zunächst an den Stellen zu suchen, an denen man zuvor bereits fündig geworden ist.
- Wenn es in Schwabing regnet, sollte man auch für den Spaziergang in Maxvorstadt einen Regenschirm mitnehmen. Eine Prognose über den Niederschlag in Hamburg ist basierend auf der Beobachtung in Schwabing hingegen erheblich unsicherer.
- Wenn in einer Schule Masern auftreten, ist die Wahrscheinlichkeit einer Übertragung in benachbarten Klassen höher als an einer Schule in 200 km Entfernung.

Dieser Grundgedanke lässt sich anhand der Abb. (1) weiter veranschaulichen. Die Abbildung bietet eine teilweise Sicht auf das Originalbild (die „Realität“), hier ein Porträtfoto, und soll das Wissen nach einer Stichproben-Erhebung veranschaulichen.

In der Abbildung sind die beiden räumlichen Koordinaten durch die Position der einzelnen Pixel in horizontaler bzw. vertikaler Richtung und die interessierende aber nur teilweise bekannte Größe $Z(x, y)$ durch den Grauwert des Bildes¹ gegeben.

Die weißen Flächen des Bildes stellen in dieser Vereinfachung die unbekannten Grauwerte des Bildes dar, die möglichst gut aus dem vorhandenen Wissen, hier also den *nicht weiß* eingefärbten Pixeln, vorhergesagt werden sollen.

Da sich das Bild in flächige Segmente zerlegen lässt, die ähnlichen Strukturen entsprechen, wie etwa den dunklen Haaren, dem hellen Gesicht, der einfarbigen Wand im Hintergrund oder dem gestreiften Hemd, ist auch in diesem Beispiel zu erwarten, dass räumlich benachbarte Beobachtungen in Form der Pixel zu gleichen Strukturen gehören und folglich ähnliche Grauwerte aufweisen.

¹Das Bild zeigt den Autor dieser Arbeit im geschätzten Alter von etwa 5 Jahren.




Abbildung 1: Teilweise beobachtete „Realität“ nach einer Stichprobenerhebung

Abb. (2) zeigt die Vorhersagen des Kriging angewendet auf das Abbild der „Realität“ nach Abb. (1). Durch den direkten Vergleich des linken und rechten Teilbildes der Abb. (2) erkennt man deutlich, dass die Berücksichtigung der räumlichen Ähnlichkeiten mittels dieser Methode qualitativ gute Vorhersagen basierend auf den Beobachtungen liefert.




Abbildung 2: Die „Realität“ (links) und die aus dem Halbwissen mittels Kriging gewonnene Vorhersage (rechts)

Dies unterstreicht die für die räumliche Statistik bedeutsame Beobachtung, dass räumlich näher beieinander liegende Beobachtungen sich ähnlicher sind als räumlich weiter entfernte Beobachtungen. Dieser Gedanke wird im nachfolgenden Kapitel erneut aufgegriffen. Des Weiteren verdeutlicht dieses Beispiel, weshalb Kriging nicht nur im Bergbau, sondern auch in anderen Disziplinen, etwa der Meteorologie oder der Umweltwissenschaft, eingesetzt wird.

1.2 Gliederung dieser Arbeit

Diese Arbeit ist wie folgt strukturiert:

- Kapitel 2 führt in die theoretischen Grundlagen der räumlichen Analyse ein. Hierbei werden neben den grundlegenden mathematischen Begriffen auch die gängigen Methoden der Geostatistik und die Kriging-Gleichungen aufgeführt.
- Kapitel 3 widmet sich dem Themengebiet Feinstaub, erläutert die Struktur der untersuchten Daten und beschreibt die vorgenommenen Schritte der Datenbereinigung.
- In Kapitel 4 werden die gewählte Herangehensweise und die Ergebnisse dieser Arbeit dargelegt und in den Kontext verwandter Arbeiten gebracht.
- Im Kapitel 5 werden die Ergebnisse diskutiert und Perspektiven für vertiefende, weitere Untersuchungen skizziert; also all die Dinge, die man noch hätte machen können, wenn Zeit dazu gewesen wäre.
- In den Anhang wurden diejenigen Überlegungen ausgelagert, die den Lesefluss im Hauptteil behindert hätten, gleichwohl zu wichtig sind, um einfach weggelassen zu werden.

2 Theoretische Grundlagen

Dieses Kapitel ist wie folgt strukturiert:

- Im Kapitel 2.1 wird das Grundprinzip des Kriging als einer Methode der Vorhersage von Zufallsvariablen im Rahmen der räumlichen Statistik erläutert.
- Das Kapitel 2.2 stellt die notwendigen Begriffe und Zusammenhänge für das weitere Verständnis bereit.
- Das Variogramm ist das zentrale Werkzeug der Modellierung im Zuge des Kriging und wird Kapitel 2.3 erläutert.
- Das Variogramm seinerseits dient als Schätzfunktion für Kovarianz-Funktionen, welche die Verbundenheit der Zufallsvariablen charakterisieren. Die gebräuchlichsten Kovarianz-Funktionen werden in Kapitel 2.4 behandelt, bevor dann
- in Kapitel 2.5 die Kriging Gleichungen motiviert und aufgeführt werden.
- Abschließend wird in Kapitel 2.6 das praxisrelevante Thema der Anisotropie hinsichtlich Phänomenologie, Detektion und Handhabung besprochen.

2.1 Grundidee des Kriging

Das von dem Geografen Waldo Tobler formulierte erste Gesetz² der Geografie lautet (vgl. Tobler 1970, S. 236):

„Everything is related to everything else, but near things are more related than distant things.“

Diese Aussage wurde von Matheron (vgl. Matheron 1971) folgendermaßen in die Sprache der Mathematik übersetzt:

- a) unter *Dingen* (als Übersetzung für „everything“) werden numerische Größen in Räumen verstanden, die mit einer Metrik versehen sind, beispielsweise also Messwerte an Orten auf der Erdoberfläche;
- b) diese Größen werden als Realisierungen von Zufallsvariablen interpretiert;
- c) die *Verbundenheit* (als Übersetzung für „related to“) dieser Zufallsvariablen wird durch Beziehungen ihrer Erwartungswerte und Kovarianzen ausgedrückt.

Kriging ist eine Methode zur Vorhersage von Werten an Orten, an denen *keine* Beobachtungen vorliegen. Um den Vorhersageprozess mathematisch handhabbar zu machen, beschränkt Kriging die Klasse der Prädiktoren auf *lineare Funktionen* der beobachteten Werte, wodurch das Anpassungsproblem auf die Bestimmung einer endlichen Anzahl von Koeffizienten reduziert wird.

Das dahinterstehende Optimierungsproblem wird durch die Festlegung folgender Nebenbedingungen definiert:

- 1) der mittlere quadratische Vorhersagefehler sollte minimiert werden, das heißt, der Prädiktor sollte *präzise* sein;

²Ob es sich hierbei im strengen Sinne um ein Gesetz handelt oder um eine in der Geophysik bewährte Heuristik wird z. B. in Miller 2004 thematisiert. Die Antwort auf diese Frage ist allerdings für die weiteren Überlegungen unerheblich.

- 2) der Prädiktor sollte im Durchschnitt dem wahren Wert entsprechen, das heißt, er sollte *unverzerrt* sein.

Diese Anforderungen führen schließlich auf ein lineares Gleichungssystem mit einer *eindeutigen* Lösung. Der resultierende Prädiktor wird daher als **Best Linear Unbiased Predictor** oder auf deutsch „bester linearer unverzerrter Prädiktor“ (kurz BLUP) bezeichnet.

Eine Voraussetzung für die Bestimmung der optimalen Gewichte des Gleichungssystems besteht darin, die räumliche Abhängigkeit der Beobachtungen quantitativ zu beschreiben. Genau hierzu dienen die im folgenden Kapitel eingeführten Kovarianz-Funktionen und die Semivarianz.

Das skizzierte Grundprinzip des Kriging wird in Kapitel 2.5 näher ausgearbeitet.

2.2 Grundlegende Begriffe

Das Fundament der nachfolgenden Überlegungen bildet die Annahme, dass die räumlichen Beobachtungen Realisierungen eines Zufallsfeldes sind.

Im Folgenden bezeichne $(\Omega, \mathcal{F}, \mathbb{P})$ einen Wahrscheinlichkeitsraum, wobei

- Ω eine beliebige Menge
- $\mathcal{F}$ eine σ -Algebra auf Ω
- $\mathbb{P}$ ein Wahrscheinlichkeitsmaß auf $\mathcal{F}$

bezeichnet.

Des Weiteren sei E ein vollständiger und separabler metrischer Raum mit Borel'scher σ -Algebra $\mathcal{B}(E)$ und $\mathcal{S} \subset \mathbb{R}^d$ eine abzählbare Teilmenge mit $d \in \mathbb{N}$, $d \geq 2$.

Definition 2.1. Zufallsfeld

Eine Familie von Zufallsvariablen $Z_{\mathcal{S}} := \{Z(s), s \in \mathcal{S}\}$ auf $(\Omega, \mathcal{F}, \mathbb{P})$ heißt Zufallsfeld oder stochastischer Prozess. Insbesondere sind die einzelnen Zufallsvariablen messbare Abbildungen: $Z : \Omega \times \mathcal{S} \rightarrow \mathbb{R}$ (vgl. z. B. Spodarev, Shmileva und Roth 2015, S. 322, Adler und Taylor 2007, S. 7).

Es ist wichtig zu betonen, dass die einzelnen Zufallsvariablen $Z(s)$, die ein Zufallsfeld $Z_{\mathcal{S}}$ konstituieren, *nicht stochastisch unabhängig* sind, sondern entsprechend dem Aspekt der Verbundenheit des Tobler'schen Gesetzes (vgl. Punkt c) der Auflistung in Kap. 2.1 oben) sehr wohl miteinander in Beziehung stehen.

Durch die folgende Einschränkung ergibt sich aus der Definition eines Zufallsfeldes die Definition eines Gauß'schen Zufallsfeldes:

Definition 2.2. Gauß'sches Zufallsfeld

Ein Zufallsfeld $Z_{\mathcal{S}}$ auf einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, \mathbb{P})$ heißt Gauß'sches Zufallsfeld³, wenn für *alle* endlichen, nicht-leeren Teilmengen $\mathcal{J} \subset \mathcal{S}$ der Mächtigkeit $\#\mathcal{J} = n \in \mathbb{N}$ der Zufallsvektor

$$Z_{\mathcal{J}} := (Z_j)_{j \in \mathcal{J}} = (Z_{j_1}, Z_{j_2}, \dots, Z_{j_n}) \quad (1)$$

³Gauß'sche Zufallsfelder werden in Lehrbüchern der Stochastik synonym auch als Gauß-Prozesse bezeichnet (vgl. z. B. Schmidt 2011, S. 462, Meintrup und Schäffler 2005, S. 344).

eine multivariate Normal-Verteilung besitzt (vgl. z. B. Diggle und Ribeiro 2007, S. 46f, Montero, Fernández-Avilés und Mateau 2015, S. 13). Ausgeschrieben ist Gl. (1) gleichbedeutend zu

$$(Z_{j_1}, Z_{j_2}, \dots, Z_{j_n}) = (Z(s_{j_1}), Z(s_{j_2}), \dots, Z(s_{j_n})) \sim \mathcal{N}_n(\mu, \Sigma), \quad (2)$$

mit den bekannten Parametern der n-dimensionale Normal-Verteilung $\mathcal{N}_n$

- dem Erwartungswert-Vektor μ
- einer symmetrischen, positiv semi-definiten Kovarianz-Matrix Σ .

Nun existiert in der Realität meist nur eine einzige Realisation $z(s)$ der Zufallsvariablen $Z(s)$. Aus nur *einer* bekannten Merkmalsausprägung je Ort können ohne weitere Annahmen aber weder Erwartungswert noch Kovarianz geschätzt werden. Dies resultiert daraus, dass es nicht möglich ist, die wahrscheinlichkeitstheoretischen Eigenschaften eines Zufallsfeldes zu bestimmen, wenn nur eine einzige Realisierung vorliegt (dies wäre vergleichbar mit einer Schätzung basierend auf einer Stichprobe vom Umfang eins). Um konsistente Inferenz zu ermöglichen, sind hingegen viele Realisierungen notwendig.

Darüber hinaus ist selbst von dieser einen Realisierung nur ein Teil bekannt, nämlich die Werte an den Punkten der Stichproben-Ziehung.

Die Lösung für diese Schwierigkeit besteht darin, geeignete Annahmen bezüglich der räumlichen Homogenität oder *Stationarität* zu treffen.

Die Idee hinter dieser Annahme besteht darin, Wiederholungen der (nicht zugänglichen) Realisierungen an *einem* Ort durch Wiederholungen im Raum zu ersetzen. Das bedeutet, dass Werte, die an verschiedenen Orten im untersuchten Gebiet beobachtet werden, dieselben Eigenschaften besitzen und mathematisch als Realisierungen desselben Zufallsfeldes betrachtet werden können. Die Stationaritätshypothese impliziert somit, dass die gemeinsamen Verteilungen des Zufallsfeldes translationsinvariant ist.

Die folgenden Ausführungen zu Stationarität und Isotropie finden sich auch z. B. in N. A. C. Cressie 1993, S. 52-53, Chiles und Delfiner 1999, S. 16-17, Montero, Fernández-Avilés und Mateau 2015, S. 14-16, Benndorf 2023, S. 107, Schmid und Sapargali 2026, S. 52-57.

Definition 2.3. Strenge Stationarität

Das Zufallsfeld Z_S heißt streng stationär, wenn für alle $k \in \mathbb{N}$ die Familien von Zufallsvariablen

$$\{Z(s_1), Z(s_2), \dots, Z(s_k)\}$$

und

$$\{Z(s_1 + h), Z(s_2 + h), \dots, Z(s_k + h)\}$$

für beliebige Punkte $s_1, s_2, \dots, s_k \in \mathcal{S}$ und jeden Translationsvektor $h \in \mathbb{R}^d$, deren verschobene Punkte noch im Gebiet $\mathcal{S}$ liegen, dieselbe gemeinsame Verteilungsfunktion besitzen.

Anders ausgedrückt: Die gemeinsame Verteilungsfunktion

$$F_Z(z)(Z(s_1), Z(s_2), \dots, Z(s_k)) := \mathbb{P}(Z(s_1) \leq z_1, Z(s_2) \leq z_2, \dots, Z(s_k) \leq z_k)$$

der Familie $\{Z(s_1), Z(s_2), \dots, Z(s_k)\}$ wird durch eine Translation um eine beliebigen Vektor h nicht verändert.

Hierbei handelt es sich um eine sehr restriktive Bedingung. Aus diesem Grund wird diese Forderung meist gelockert und durch die der schwachen Stationarität ersetzt, die nur die ersten beiden Momente des Zufallsfeldes involviert.

Definition 2.4. Schwache Stationarität, stationäre Kovarianz-Funktion

Das Zufallsfeld Z_S heißt schwach stationär, wenn es die folgenden Bedingungen erfüllt:

- Der Erwartungswert existiert und ist konstant; er hängt also nicht vom Ort s ab:

$$\mathbb{E}(Z(s)) = \mu(s) = \mu. \quad (3)$$

- Die Kovarianz existiert für jedes Paar von Zufallsvariablen $Z(s)$ und $Z(s+h)$ und hängt *nur* vom Verschiebungsvektor h ab, der die Orte s und $(s+h)$ verbindet, jedoch nicht von deren konkreten Lage innerhalb des betrachteten Raums $\mathcal{S}$:

$$\text{Cov}(Z(s), Z(s+h)) =: C(h), \quad \forall s \in \mathcal{S} \text{ und } h \in \mathbb{R}^d. \quad (4)$$

Die Funktion $C(\cdot) : \mathbb{R}^d \rightarrow \mathbb{R}$ wird als stationäre Kovarianz-Funktion bezeichnet.

Da nach Voraussetzung die Kovarianz eines schwach stationären Zufallsfeldes nur vom Verschiebungsvektor h abhängt, folgt daraus, dass die Varianz eines solchen Zufallsfeldes existiert und konstant ist, denn:

$$\text{Var}(Z(s)) = \text{Cov}(Z(s), Z(s)) = C(0) =: \sigma^2 \in \mathbb{R}_+ \setminus \{0\}. \quad (5)$$

Definition 2.5. Isotropie/Anisotropie

Falls die Kovarianz-Funktion $C(\cdot)$ eines stationären Zufallsfeld rotationsinvariant ist, d. h. nur von der Distanz $\|s_1 - s_2\|$ zwischen den betrachteten Punkten s_1 und s_2 abhängt aber *nicht* von der Richtung des Differenzvektors $(s_1 - s_2)$, dann wird das Zufallsfeld als isotrop bezeichnet, andernfalls als anisotrop.

Unter bestimmten Umständen lässt sich der Fall eines anisotropen Zufallsfeldes durch Koordinaten-Transformation auf den eines isotropen Zufallsfeldes zurückführen. Die Handhabung von Anisotropie wird detailliert in Kap. 2.6 behandelt.

Kovarianzfunktionen beschreiben die räumliche Abhängigkeit vollständig. In der Praxis arbeitet die räumliche Statistik meist mit der eng verwandten Semivarianz und deren grafischen Darstellung, dem Variogramm.

2.3 Semivarianz und Variogramm

Die Semivarianz ist die Größe, mit deren Hilfe die Ähnlichkeit von zwei Beobachtungen $Z(s_j)$ und $Z(s_k)$ eines Zufallsfeldes quantifiziert werden kann und ist dadurch eine wichtige Bestimmungsgröße des Kriging.

Definition 2.6. Semivarianz

Die Semivarianz γ eines Zufallsfeldes ist definiert als die Varianz der Differenz zweier Zufallsvariablen des Zufallsfeldes:

$$\gamma(s_j - s_k) = \frac{1}{2} \text{Var}[Z(s_j) - Z(s_k)], \quad \forall s_j, s_k \in \mathcal{S}. \quad (6)$$

Anmerkung: Die Semivarianz gemäß dieser Definition wird in der englischsprachigen Literatur als *variogram* oder auch *semivariogram* bezeichnet.

Nun bezeichnet man im deutschen Sprachgebrauch mit Variogramm allerdings die grafische Darstellung des Verlaufs der Semivarianz, weshalb mit Blick auf eine saubere Unterscheidung zwischen der Funktion einerseits und ihrer Darstellung andererseits die Notation Semivarianz für die Funktion und Variogramm für ihren Graphen gewählt wurde.

Nach den bekannten Rechenregeln für die Varianz von Zufallsvariablen (vgl. z. B. Henze 2019, S. 102) lässt sich Gl. (6) auch schreiben als :

$$\gamma(s_j - s_k) = \frac{1}{2} [\text{Var}(Z(s_j)) + \text{Var}(Z(s_k))] - \text{Cov}(Z(s_j), Z(s_k)), \quad (7)$$

was sich bei Beschränkung auf schwach stationäre Zufallsfelder unter Nutzung von Gl. (5) weiter vereinfacht zu:

$$\begin{aligned} \gamma(s_j - s_k) &= \frac{1}{2} [\text{Var}(Z(s_j)) + \text{Var}(Z(s_k))] - \text{Cov}(Z(s_j), Z(s_k)) = \\ &= \frac{1}{2} [C(0) + C(0)] - C(s_j - s_k) = \sigma^2 - C(h), \text{ mit } h = (s_j - s_k) \iff \\ &\gamma(h) = \sigma^2 - C(h) = \sigma^2 (1 - \rho(h)), \text{ wobei } \rho(h) := \frac{C(h)}{\sigma^2}. \end{aligned} \quad (8)$$

Die Funktion $\rho(h) : \mathbb{R}^d \rightarrow [-1, 1]$ aus Gl. (8) wird Korrelations-Funktion genannt.

Damit folgt schließlich im Falle eines isotropen Zufallsfeldes:

$$\gamma(r) = \sigma^2 - C(r) = \sigma^2 (1 - \rho(r)), \text{ mit } r := \|h\|. \quad (9)$$

Aus der Kenntnis von zwei der drei Größen Varianz, Kovarianz-Funktion und Semivarianz eines schwach stationären Zufallsfeldes lässt sich also die dritte Größe berechnen.

2.3.1 Schätzung der empirischen Semivarianz

Unter der Annahme eines isotropen Zufallsfeldes gilt für die Semivarianz nach Gl. (8):

$$\begin{aligned} \gamma(s_j - s_k) &= \frac{1}{2} \text{Var}[Z(s_j) - Z(s_k)] = \mathbb{E}([Z(s_j) - Z(s_k)]^2) - [\mathbb{E}(Z(s_j) - Z(s_k))]^2 = \\ &= \mathbb{E}([Z(s_j) - Z(s_k)]^2) - (\mu - \mu)^2 = \mathbb{E}([Z(s_j) - Z(s_k)]^2) \end{aligned}$$

womit ein Schätzer für die Semivarianz gegeben ist durch:

$$\hat{\gamma}(r) = \frac{1}{2\#N(r)} \sum_{j,k \in N(r)} (z(s_j) - z(s_k))^2, \quad (10)$$

wobei $N(r) = \{(s_j, s_k) : \|s_j - s_k\| = r \wedge s_j, s_k \in \mathcal{S}\}$ die Menge aller Orte im Gebiet $\mathcal{S}$ mit Abstand r bezeichnet.

Falls die Orte $s \in \mathcal{S} \subset \mathbb{R}^d$ der Zufallsvariablen $Z(s)$, die gesamthaft das Zufallsfeld aufbauen können, kontinuierliche Werte annehmen (man spricht von geostatistischen Daten), wird die Mächtigkeit $\#N(r)$ der Mengen für verschiedene Werte von r typischerweise bei Eins oder Null liegen, was zu einem „verwackelten“ Verlauf des Schätzers $\hat{\gamma}$ der Semivarianz führt.

Man verwendet daher in der Praxis das Vorgehen der Klasseneinteilung und partitioniert das Intervall $[0, r_{max}]$ anhand von Stützstellen $\{r_m\}$ mit $0 = r_0 < r_1 < \dots < r_M = r_{max}$ in M disjunkte Intervalle $R_m = [r_m, r_{m+1})$, $0 \leq m < M$.

Die so definierten Abstandsklassen $\{R_m\}$ werden auch als *Lag* bezeichnet⁴.

Bei der Wahl einer geeigneten Klassenaufteilung sollte beachtet werden, dass es für n Datenpunkten einer Beobachtung maximal $n \cdot (n - 1)/2$ paarweise verschiedenen Distanzen gibt. Die Anzahl der in die Berechnung einbezogenen Datenpunkte sollte somit hinreichenden groß sein, um eine aussagekräftige Schätzung zu ermöglichen.

Nach dieser Vorarbeit wird dann die Zählung nach Gl. (10) dahingehend modifiziert, dass man die Abstände $\|s_j - s_k\|$ in den jeweiligen Klassen betrachtet:

$$\hat{\gamma}(r_m) = \frac{1}{2\#N_m} \sum_{m: (s_j - s_k) \in R_m} (z(s_j) - z(s_k))^2, \quad (11)$$

wobei $N_m = \{(s_j, s_k) : \|s_j - s_k\| \in R_m \wedge s_j, s_k \in \mathcal{S}\}$ die Menge aller Orte im Gebiet $\mathcal{S}$ in der Abstands-Klasse R_m bezeichnet. Der Schätzer gemäß Gl. (11) wird auch *Matheron Semivarianz-Schätzer* genannt.

Ein weiterer, gängiger Semivarianz-Schätzer wurde in N. Cressie und Hawkins 1980 unter Annahme von normal-verteilten Zufallsvariablen $X(s)$ (was auf eine χ^2 -Verteilung des Ausdrucks $(X(s_j) - X(s_k))^2$ führt) entwickelt und wird daher auch *Cressie-Hawkins Semivarianz-Schätzer* genannt:

$$\hat{\gamma}(r_m) = \frac{1}{0.457 + \frac{0.494}{\#N_m} + \frac{0.045}{(\#N_m)^2}} \cdot \left(\frac{1}{2\#N_m} \sum_{m: (s_j - s_k) \in R_m} \sqrt{|z(s_j) - z(s_k)|} \right)^4 \quad (12)$$

Es existieren weitere Schätzer für die Semivarianz (vgl. z. B. Dowd 1984, Genton 1998), die für andere unterstellte Eigenschaften des Zufallsfelds die Schätzfunktion optimieren. Die Vielzahl dieser, an verschiedene Voraussetzungen angepassten Varianten unterstreicht die eingangs bereits betonte Bedeutung der Semivarianz für das Prognoseverfahren des Kriging.

Für die Schätzer mit diskretisierten Abständen $\{r_m\}$ gibt es für die Festlegung der Anzahl M der Klassen und deren jeweiligen Breite $(r_{m+1} - r_m)$ keine theoretischen Empfehlungen und ist daher Teil der operativen Feinabstimmung (vgl. hierzu auch Benndorf 2023,

⁴Deutsche Übersetzungen haben sich nicht durchgesetzt, weshalb diese Bezeichnung als Fachbegriff im weiteren Verlauf beibehalten wird.

S. 111).

In Abb. (3) ist beispielhaft ein isotropes Gauß'sches Zufallsfeld und rechts daneben die korrespondierenden Variogramme nach Matheron und Cressie-Hawkins dargestellt.




Abbildung 3: Farbodierte Realisierung $z(x,y)$ eines Gauß'schen Zufallsfelds (links) und die korrespondierenden Semivarianz-Schätzfunktionen nach Matheron und Cressie-Hawkins (rechts)

Bei der Betrachtung der Variogramme in Abb. (3) fallen zwei Dinge auf:

- 1) Mit steigenden Lag r konvergiert die Semivarianz gegen einen konstanten Wert, der bei dem hier beispielhaft gewählten Zufallsfeld etwa bei Eins liegt.
- 2) Der Durchmesser der ähnlich gefärbten Gebiete innerhalb des Zufallsfeld scheint in etwa mit dem Lag zusammenzufallen, bei dem die Variogramme einen konstanten Wert erreichen. Dies erkennt man beispielhaft an dem annähernd kreisförmigen, rötlich gefärbten Areal $(\Delta x, \Delta y) = ([20 - 40], [20 - 40])$.

Die in diesem Zusammenhang üblichen Fachbegriffe werden im nächsten Unterkapitel bereitgestellt, in dem auch die Methodik zur Stichproben-Ziehung aus einem Gauß'schen Zufallsfeld wie etwa in Abb. (3) ausgeführt wird.

2.4 Kovarianz-Funktionen

Mit der Zielsetzung einer späteren theoretischen Beschreibung ist es hilfreich, die Eigenschaften einer Kovarianz-Funktion herauszuarbeiten, wenn für das korrespondierende Zufallsfeld die Gültigkeit der schwachen Stationarität und der Isotropie angenommen werden kann.

So lässt sich aus der allgemein gültigen Forderung, dass die Varianz einer Zufallsvariablen stets größer-gleich Null sein muss, ableiten, dass die stationäre Kovarianz-Funktion nach Gl. (4) positiv-semidefinit sein muss (vgl. z. B. Webster und Oliver 2007, S. 55ff, Journal

und Huijbregts 1989, S. 35f).

Daraus folgen unmittelbar die folgenden Eigenschaften einer Kovarianz-Funktion:

- 0) Kovarianz-Funktionen sind abgeschlossen unter Addition und Multiplikation; insbesondere sind Linearkombinationen stationärer Kovarianz-Funktionen ihrerseits wieder stationäre Kovarianz-Funktionen (vgl. z. B. Rasmussen und Williams 2006, Kap. 4.2, Murphy 2023, Kap. 18.2).
- 1) $C(r) = C(-r)$, $r \in \mathbb{R}_+$: die Kovarianz-Funktion ist eine gerade Funktion.
- 2) $|C(r)| \leq C(0) = \text{Var}(Z(s)) = \sigma^2$,

die ergänzt werden durch die weitere, theoretisch *nicht* notwendige aber praktisch fast immer erfüllte

- 3) Eigenschaft der räumlich begrenzten Wechselwirkung: $\lim_{r \rightarrow \infty} C(r) = 0$. Zusammen mit Gl. (9) folgt damit sofort, dass $\lim_{r \rightarrow \infty} \gamma(r) = \sigma^2$, das heißt, die Semivarianz konvergiert gegen einen konstanten Wert, in Übereinstimmung mit den Beobachtungen, die mit Blick auf Abb. (3) angestellt wurden.

Im folgenden werden einige der theoretischen Modell-Funktionen aufgeführt, die diesen Rahmenbedingungen für schwach-stationäre und isotrope Korrelationen gemäß Gl. (9) genügen und für $\mathcal{S} \subset \mathbb{R}^3$ definiert sind.

○ Sphärisches Modell

$$\rho_{sph}(r; \ell) := \begin{cases} 1 - \frac{3}{2}\frac{r}{\ell} + \frac{1}{2}\frac{r^3}{\ell^3}, & \text{falls } 0 \leq r < \ell \\ 0, & \text{falls } r \geq \ell \end{cases}, \quad \ell \in \mathbb{R}_+ \setminus \{0\} \quad (13)$$




Abbildung 4: Korrelations-Funktion des sphärischen Modells für verschiedene Parameter ℓ

Aus der Abb. (4) kann man gut erkennen, dass der Parameter ℓ in guter Näherung die Distanz r bestimmt, ab der die Korrelations-Funktion auf Null gefallen ist.

Durch die Vorgabe eines Erwartungswerts μ , einer zwei-dimensionalen Menge $\mathcal{S}$ an Punkten und einer Varianz σ^2 des isotropen, schwach stationären Zufallsfeldes, lässt sich für ein konkretes Korrelations-Modell die Kovarianz-Funktion und damit die Normal-Verteilung eines Gauß'schen Zufallsfeld nach Gl. (1) bestimmen.

Aus dieser Normal-Verteilung wiederum können Stichproben gezogen werden (das genaue Vorgehen ist z. B. in Kroese und Botev 2015 beschrieben), die sich als farbige Fläche darstellen lassen. Hierbei wird die Realisierung $z(\tilde{s})$ am Ort $\tilde{s} = (\tilde{x}, \tilde{y})$ über eine Farbskala kodiert. Diese Vorgehensweise ist im linken Teilbild der Abb. (5) verdeutlicht und wird nachfolgend auch für die weiteren, aufgeführten Kovarianz-Funktionen angewendet.




Abbildung 5: Realisierung eines isotropen, schwach stationären Gauß'schen Zufallsfelds mit sphärischem Modell (links) und das zugehörige Korrelogramm (rechts)

○ Exponentielles Modell

$$\rho_{exp}(r; \ell) := \exp\left(-\frac{r}{\ell}\right), \ell \in \mathbb{R}_+ \setminus \{0\} \quad (14)$$




Abbildung 6: Korrelations-Funktion des exponentiellen Modells für verschiedene Parameter ℓ




Abbildung 7: Realisierung eines isotropen, schwach stationären Gauß'schen Zufallsfelds mit exponentiellem Modell (links) und das zugehörige Korrelogramm (rechts)

Im Anhang A.1 sind mit dem Stable-, dem Matérn- und dem Gauß'schen Modell drei weitere der in der Praxis relevante Kovarianz-Modelle aufgeführt.

Die obenstehenden Ausführungen zu stationären Kovarianz-Funktionen sind beispielsweise auch in den Lehrbüchern Montero, Fernández-Avilés und Mateau 2015, Kap. 3.5.1 Oliver und Webster 2015, Kap. 3.3.2, Chiles und Delfiner 1999, Kap. 2.5.1, Rasmussen und Williams 2006, Kap. 4.2.1 nachzulesen.

2.4.1 Nugget Effekt

Im Falle eines schwach stationären Zufallsfeldes folgt aus der in Kapitel 2.2 hergeleiteten Gl. (4), dass die Beziehung

$$\gamma(h) = \frac{1}{2} \text{Var} [Z(s+h) - Z(s)] \implies \lim_{h \rightarrow 0} \gamma(h) = 0 \quad (15)$$

gilt⁵.

Nun kommt es unter realen Bedingungen vor, dass

$$\lim_{h \rightarrow 0} \gamma(h) = c_0 > 0 \quad (16)$$

beobachtet wird, das heißt, es gibt eine Unstetigkeit der Semivarianz $\gamma(\cdot)$ in der Nähe des Ursprungs.

Das Auftreten dieser Unstetigkeit wird nach Matheron 1971, Kap. 2.7 als Nugget-Effekt und die Sprunghöhe c_0 in der Gl. (16) als Nugget bezeichnet.

Ursächlich für diese Diskontinuität können nach Chiles und Delfiner 1999, S. 51f sein:

- eine Mikrostruktur mit einer Reichweite, die kürzer ist als der Stichprobenträger (beispielsweise der Bohrkopf für Probebohrungen im Bergbauwesen); dieser Fall tritt mitunter beim Goldabbau auf und war namensgebend für den Nugget-Effekt (vgl. z. B. Carrasco 2010);
- eine Struktur mit einer Reichweite, die kürzer ist als der kleinste technisch mögliche Abstand zwischen den Messpunkten oder
- Mess- und Positionierungsfehler.

Unabhängig von der genauen Ursache des Nugget-Effekts lässt sich dieser mathematisch als eine Fallunterscheidung in den Definitionen der Kovarianz- bzw. Korrelationsfunktionen des Kapitels 2.4 einführen.

Beispielsweise würde die Korrelationsfunktion für das Gauß'sche Modell nach Gl. (34) durch das Hinzufügen eines Nugget-Effekts der Größe c_0 wie folgt modifiziert:

$$\rho_{exp}(r; \ell) := \begin{cases} \exp\left(-\frac{r^2}{\ell^2}\right), & \text{falls } r > 0 \\ c_0, & \text{falls } r = 0 \end{cases}, \quad \ell \in \mathbb{R}_+ \setminus \{0\} \quad (17)$$

Abb. (8) zeigt zwei Realisierungen eines isotropen, schwach-stationären Gauß'schen Zufallsfeldes mit Gauß'scher Korrelationsfunktion einmal mit und einmal ohne Nugget. Man erkennt deutlich, dass das Einführen eines Nugget-Effekts die auch mit dem bloßen Auge erkennbaren Strukturen der Verbundenheit verwässert.

⁵Genau genommen, geht zusätzlich die nicht explizit erwähnte Annahme ein, dass für das Zufallsfeld $Z(s) \in \mathcal{L}^2$ erfüllt ist, wobei $\mathcal{L}^2$ aus allen quadratisch integrierbaren, messbaren Funktionen f besteht, also $\|f\|_{\mathcal{L}^2} < \infty$. Details bezüglich der Notation finden sich z. B. in Forster 2017, Kap. 12.




Abbildung 8: Realisierung eines isotropen, schwach stationären Gauß'schen Zufallsfelds mit Gauß'scher Korrelations-Funktion ohne (links) und mit Nugget-Effekt (rechts)

2.4.2 Übersicht der eingeführten Fachbegriffe

In Ergänzung zu Abb. (9) sind nachfolgend die im Kontext der Variogramm-Analyse gängigen Fachbegriffe zusammengefasst:




Abbildung 9: Illustration der Fachbegriffe Range, Sill, Partial Sill und Nugget in Beziehung zur Semivarianz $\gamma(r)$ und der Korrelations-Funktion $\rho(r)$

- Der Range beschreibt die durchschnittliche Reichweite der räumlichen Korrelation.

Außerhalb dieser Reichweite besteht keine statistische Abhängigkeit der Beobachtungen mehr. Der Range wird maßgeblich durch den Parameter ℓ der in Kap. 2.4 eingeführten Kovarianz-Modelle bestimmt.

- Der Sill ist der Grenzwert (das maximale Plateau) den die Semivarianz $\gamma(r)$ für unendlich große Abstände erreicht.
- Der Nugget beschreibt die Unstetigkeit an der Stelle $r = 0$ (vgl. Kap. 2.4.1).
- Der Partial Sill ist das Plateau, welches durch die Differenz (Sill-Nugget) charakterisiert wird.

2.5 Kriging-Gleichungen

Unter Kriging subsummiert man eine Klasse geostatistischer Schätzverfahren, deren Ziel die möglichst genaue Vorhersage einer räumlichen (oder als Erweiterung auch raumzeitlichen) Zufallsvariable an nicht beobachteten Orten ist. Im Gegensatz zu anderen Interpolationsverfahren werden hierbei sowohl die räumliche Korrelation als auch die Unsicherheit der Schätzung explizit berücksichtigt.

Die Herleitung der Kriging-Gleichungen basiert auf drei grundlegenden Prinzipien:

- Die Vorhersage erfolgt als lineare Kombination der Beobachtungen.
- Die Schätzung soll erwartungstreu sein. Das heißt für einen Schätzer θ der gesuchten Größe T soll $\mathbb{E}(\theta) = T$ gelten.
Dies ist gleichbedeutend zu der Forderung einer unverzerrten Schätzung, d. h. mit $b_\theta = (\mathbb{E}(\theta) - T)$ soll gelten, dass $b_\theta = 0$ erfüllt ist (vgl. z. B. Henze 2019, S. 235).
- Unter allen unverzerrten linearen Schätzern wird diejenige gewählt, deren Fehlervarianz minimal ist.

Die verschiedenen Kriging-Verfahren unterscheiden sich im Wesentlichen durch die Annahmen über den Erwartungswert des zugrunde liegenden Zufallsfeldes. Im Folgenden werden zunächst die gemeinsame Grundidee und anschließend die Herleitung der drei Varianten Simple, Ordinary und Universal Kriging erläutert.

2.5.1 Methodik des Kriging

Es sei eine Zufallsvariable $Z(s)$ mit $s \in \mathcal{S}$ gegeben. Gesucht ist eine Vorhersage am Ort s_0 .

Die Kriging-Schätzung wird als gewichtete Summe der Beobachtungen angesetzt:

$$\hat{Z}(s_0) = \sum_{i=1}^n \lambda_i Z(s_i), \quad (18)$$

wobei λ_i die noch unbekannten Gewichte darstellen.

Intuitiv sollen die Gewichte so gewählt werden, dass Beobachtungen mit hoher räumlicher Ähnlichkeit stärker berücksichtigt werden als weiter entfernte Beobachtungen mit geringerer Ähnlichkeit. Gleichzeitig sollen Redundanzen vermieden werden: Liegen mehrere Messpunkte sehr dicht beieinander, liefern sie nur begrenzte zusätzliche Information und erhalten daher geringere Einzelgewichte.

Die Bestimmung der Gewichte erfolgt über ein Optimierungsproblem. Hierzu wird die mittlere quadratische Vorhersageabweichung

$$\sigma_{\text{opt}} = \text{Var} \left(\hat{Z}(s_0) - Z(s_0) \right) \quad (19)$$

minimiert, wobei zusätzlich die Bedingung der Erwartungstreue erfüllt werden muss. Die Varianz des Schätzfehlers hängt ausschließlich von der Kovarianzstruktur beziehungsweise äquivalent von der Semivarianz des Zufallsfeldes ab. Dadurch fließen die räumlichen Abhängigkeiten unmittelbar in die Berechnung der Gewichte ein.

2.5.2 Simple Kriging

Beim Simple Kriging wird angenommen, dass der Erwartungswert des Zufallsfeldes bekannt und im gesamten Untersuchungsgebiet konstant ist,

$$\mathbb{E}(Z(s)) = m. \quad (20)$$

Diese Annahme vereinfacht die Herleitung erheblich, da keine zusätzlichen Bedingungen an die Gewichte notwendig sind.

Die resultierende Schätzung kann geschrieben werden als:

$$\hat{Z}(s_0) = m + \sum_{j=1}^n \lambda_j (Z(s_j) - m), \quad (21)$$

wobei n die Anzahl der Beobachtungen bezeichnet.

Somit werden nicht die absoluten Beobachtungswerte interpoliert, sondern deren Abweichungen vom bekannten Mittelwert m .

Die Gewichte werden so gewählt, dass die Varianz des Schätzfehlers minimal wird. Da der Mittelwert bekannt ist, genügt hierfür die Lösung eines linearen Gleichungssystems, welches ausschließlich die Kovarianzen zwischen den Beobachtungspunkten sowie die Kovarianzen zum Vorhersageort enthält.

Formal ergibt sich das Gleichungssystem

$$\mathbf{C} \cdot \boldsymbol{\lambda} = c, \quad (22)$$

wobei

- $\mathbf{C}$ die Kovarianzmatrix der Beobachtungen,
- c der Kovarianzvektor zwischen Beobachtungen und Vorhersageort sowie
- $\boldsymbol{\lambda}$ der Vektor der unbekannten Gewichte

symbolisieren. Für eine eindeutige Lösbarkeit des Gleichungssystems ist es erforderlich, dass die Kovarianzmatrix $\mathbf{C}$ positiv definit sein muss.

Simple Kriging besitzt damit die mathematisch einfachste Form aller Kriging-Verfahren. In praktischen Anwendungen ist die Voraussetzung eines bekannten globalen Mittelwertes allerdings selten erfüllt. Aus diesem Grund wird Simple Kriging vergleichsweise selten eingesetzt und dient hauptsächlich als theoretischer Ausgangspunkt.

2.5.3 Ordinary Kriging

In den meisten Anwendungen ist der Mittelwert des Prozesses unbekannt. Stattdessen wird lediglich angenommen, dass dieser innerhalb einer zu spezifizierenden Nachbarschaft $N \subset \mathcal{S}$ konstant ist, also

$$\mathbb{E}(Z(s)) = m, \quad s \in N, \quad (23)$$

wobei m unbekannt bleibt.

Die große Bedeutung der Nachbarschaft wird z. B. in Webster und Oliver 2007, Kap. 8.5 diskutiert, wo auch empirische Regeln zu deren Festlegung aufgeführt sind.

Da der Mittelwert nicht bekannt ist, muss verhindert werden, dass die Schätzung systematisch verzerrt wird. Dies führt unmittelbar zur Nebenbedingung

$$\sum_{j=1}^n \lambda_j = 1. \quad (24)$$

Diese Bedingung stellt sicher, dass sich der unbekannte Mittelwert bei der Bildung des Erwartungswertes herauskürzt und die Schätzung unverzerrt bleibt.

Die Optimierung erfolgt wiederum über die Minimierung der Schätzfehlervarianz. Aufgrund der zusätzlichen Nebenbedingung kann das Optimierungsproblem jedoch nicht mehr direkt gelöst werden. Stattdessen wird die Methode der Lagrange-Multiplikatoren verwendet.

Hierzu wird die Zielfunktion L um den Lagrange-Multiplikator ξ erweitert:

$$L = \sigma_{\text{opt}} + 2\xi \left(\sum_j \lambda_j - 1 \right). \quad (25)$$

Durch Ableiten nach allen Gewichten und dem Lagrange-Multiplikator ξ entsteht das Kriging-Gleichungssystem

$$\begin{bmatrix} \mathbf{C} & \mathbf{1} \\ \mathbf{1}^T & 0 \end{bmatrix} \begin{bmatrix} \lambda \\ \xi \end{bmatrix} = \begin{bmatrix} c \\ 1 \end{bmatrix}. \quad (26)$$

Im Vergleich zum Simple Kriging wird somit lediglich eine zusätzliche Gleichung ergänzt, welche die Unverzerrtheit garantiert.

Ordinary Kriging stellt den am häufigsten verwendeten Kriging-Ansatz dar, da keine Kenntnis des globalen Mittelwertes erforderlich ist und dennoch optimale lineare Schätzungen erzeugt werden.

2.5.4 Universal Kriging

Während Ordinary Kriging einen lokal konstanten Mittelwert voraussetzt, reicht diese Annahme in vielen Anwendungen nicht aus.

Universal Kriging zerlegt den Prozess daher in einen deterministischen Trend und einen räumlich korrelierten Restprozess $\epsilon(s)$, also

$$Z(s) = m(s) + \epsilon(s). \quad (27)$$

Dabei wird der Trend als Linearkombination bekannter Basisfunktionen beschrieben

$$m(s) = \sum_{k=1}^p \beta_k f_k(s), \quad (28)$$

wobei

- $f_k(s)$ bekannte Trendfunktionen (z. B. Polynomfunktionen) und
- β_k unbekannte Regressionsparameter

bezeichnen. Der Trend wird also durch ein multiples lineares Regressionsmodell beschrieben. Die Schätzbedingung lautet weiterhin

$$\hat{Z}(s_0) = \sum_{j=1}^n \lambda_j Z(s_j), \quad (29)$$

jedoch müssen nun zusätzlich die p Trendfunktionen reproduziert werden. Daraus ergeben sich die Nebenbedingungen

$$\sum_j \lambda_j f_k(s_j) = f_k(s_0), \quad 1 \leq k \leq p. \quad (30)$$

Im Vergleich zum Ordinary Kriging existiert somit nicht nur eine, sondern mehrere Nebenbedingungen.

Auch hier erfolgt die Herleitung über Lagrange-Multiplikatoren. Das resultierende lineare Gleichungssystem besitzt die Form

$$\begin{bmatrix} \mathbf{C} & \mathbf{F} \\ \mathbf{F}^T & \mathbf{0} \end{bmatrix} \begin{bmatrix} \lambda \\ \xi \end{bmatrix} = \begin{bmatrix} c \\ \mathbf{f}(s_0) \end{bmatrix}, \quad \xi \in \mathbb{R}^{(p+1)}, \quad (31)$$

wobei $\mathbf{F}$ die Matrix der Trendfunktionen enthält.

Universal Kriging kann daher als Verallgemeinerung des Ordinary Kriging verstanden werden. Während Ordinary Kriging lediglich einen konstanten Mittelwert zulässt, erlaubt Universal Kriging beliebige lineare Trends.

2.5.5 Zusammenfassender Überblick

Alle drei Methoden fußen auf denselben Grundannahmen einer linearen, erwartungstreuen und varianzminimalen Prädiktion mit zunehmend allgemeineren Annahmen an den Mittelwert.

- Simple Kriging:
 - ▷ m bekannt und konstant;
 - ▷ keine Nebenbedingung;
 - ▷ unrestringierte Optimierung.
- Ordinary Kriging:
 - ▷ m unbekannt, aber regional konstant;
 - ▷ eine Nebenbedingung ($\sum_j \lambda_j = 1$) und somit
 - ▷ ein Lagrange-Multiplikator.

- Universal Kriging:
 - ▷ $m(s)$ unbekannt und variabel (Trendfunktion);
 - ▷ $(p + 1)$ Nebenbedingungen und somit
 - ▷ $(p + 1)$ Lagrange-Multiplikatoren.

Diese Hierarchie erklärt zugleich, warum sich die drei Verfahren in ihrer mathematischen Struktur so ähnlich sind: Das jeweilige Kriging-System entsteht stets durch dieselbe Lagrange-Konstruktion, lediglich die Anzahl und Form der Nebenbedingungen wächst mit der Komplexität der an den Mittelwert gestellten Annahmen und erhöht folglich die Dimension des zu lösenden Gleichungssystems.

2.6 Anisotropie

In Kapitel 2.2 wurde bereits erwähnt, dass ein Semivariogramm *anisotrop* genannt wird, falls seine Form nicht nur vom Betrag des Abstandsvektors $\|s_1 - s_2\|$, sondern zusätzlich auch von dessen Richtung abhängt.

Da sich die mathematische Behandlung einfacher gestaltet, ist die Annahme der Isotropie ein sinnvoller Startpunkt, die in realen Anwendungen aber oftmals verletzt wird.

Gründe hierfür sind beispielsweise

- geologische Strukturen (Hügel, Flussläufe),
- bauliche Gegebenheiten (Häuser, Straßen),
- unterschiedliche Vegetation (Wälder, Ödland) oder
- meteorologische Einflüsse (Windströmungen, Regenwahrscheinlichkeit).

Man unterscheidet zwischen geometrischer und zonaler Anisotropie (vgl. Abb. (10)).




Abbildung 10: Illustration der geometrischen Anisotropie (links) mit den beiden unterschiedlichen Werten des Sill (—) a_1 , a_2 und der zonalen Anisotropie (rechts)

○ Geometrische Anisotropie

Die geometrische Anisotropie wird dadurch charakterisiert, dass richtungsabhängige Va-

riogramme des Zufallsfelds dieselbe Höhe des Sill aufweisen, der Sill aber bei unterschiedlichen Reichweiten (Ranges) erreicht wird.

Die Korrelation nimmt also in verschiedenen Richtungen unterschiedlich schnell ab.

◦ Zonale Anisotropie

Bei zonaler Anisotropie besitzen die richtungsabhängigen Variogramme unterschiedliche Sill-Werte, während die Reichweite nahezu identisch bleibt. Zonale Anisotropie tritt in Reinform bei realen Phänomenen eher selten auf, sondern meist in Kombination mit geometrischer Anisotropie (hybride Anisotropie). Anders als die geometrische Anisotropie lässt sich die zonale Anisotropie *nicht* auf einfache Weise in eine isotrope Struktur überführen (vgl. hierzu z. B. Chiles und Delfiner 1999, Kap. 2.5.2, Schmid und Sapargali 2026, Kap. 6).

Um eine mögliche Anisotropie aufzudecken, wird das Variogramm für unterschiedliche Richtungen berechnet. Das Vorgehen zur Schätzung dieser direktionalen Semivarianz ist der Schätzung der empirischen Semivarianz (vgl. Kapitel 2.3.1) sehr ähnlich. Lediglich findet die Einteilung in die Distanzklassen (*Lags*) hier nur für die Beobachtungen statt, die sich in einem bestimmten Winkelbereich $\vartheta \pm \Delta\vartheta$ befinden.

Das genaue Vorgehen ist detaillierter z. B. in Webster und Oliver 2007, S. 72ff, Montero, Fernández-Avilés und Mateau 2015, S. 54f beschrieben.

Beispielhaft zeigt Abb. (11) die Variogramme in X- bzw. Y-Richtung des simulierten Zufallsfelds aus Abb. (12).




Abbildung 11: Variogramm in X-Richtung (links) und Y-Richtung (rechts) eines geometrisch anisotropen Zufallsfelds




Abbildung 12: Stichprobe eines geometrisch anisotropen Gauß'schen Zufallsfelds ($\lambda = 6$)

Liefert das richtungsabhängige Variogramm Hinweise auf eine geometrische Anisotropie, so kann das zugrundeliegende Zufallsfeld möglicherweise mittels einer Koordinatentransformation in ein isotropes Zufallsfeld überführt werden. Die für die Umrechnung benötigten Größen sind aus Abb. (13) ersichtlich.




Abbildung 13: Skizze der für die Transformation der geometrischen Anisotropie verwendeten Größen a_1 , a_2 und β

Die Orientierung der Anisotropie β wird durch den Winkel zwischen der Hauptachse der Ellipse und der y -Achse bestimmt. Das Verhältnis der beiden Reichweiten

$$\lambda = \frac{a_2}{a_1}, \quad \lambda > 1,$$

mit

- der kleineren Reichweite a_1 und
- der größeren Reichweite a_2 ,

wird Anisotropieverhältnis genannt und ist ein Maß für die Richtungsabhängigkeit: Je größer λ , desto ausgeprägter ist diese.

Zur Modellierung geometrischer Anisotropie wird das Koordinatensystem so transformiert, dass die Ellipse in einen Kreis überführt wird. Die Zielsetzung der Transformation besteht darin, die Anisotropie vollständig in die Koordinaten zu verlagern, sodass anschließend ein isotropes Kovarianz-Modell verwendet werden kann.

Dies geschieht in zwei Schritten:

1) Rotation

Zunächst werden die Koordinaten um den Winkel β rotiert.

$$\begin{pmatrix} x' \\ y' \end{pmatrix} = \begin{pmatrix} \cos(\beta) & -\sin(\beta) \\ \sin(\beta) & \cos(\beta) \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}.$$

2) Skalierung

Anschließend wird entlang der kurzen Ellipsenachse skaliert:

$$\begin{pmatrix} \tilde{x} \\ \tilde{y} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & \lambda \end{pmatrix} \begin{pmatrix} x' \\ y' \end{pmatrix}.$$

Fasst man beide Schritte zusammen, so erhält man als Transformationsvorschrift

$$\begin{aligned} \tilde{x} &= x \cos(\beta) - y \sin(\beta) \\ \tilde{y} &= \lambda x \sin(\beta) + \lambda y \cos(\beta) \end{aligned} \tag{32}$$

wodurch die Ellipse in einen Kreis überführt wird.

Im transformierten Koordinatensystem kann anschließend ein gewöhnliches isotropes Variogrammodell verwendet werden. Bei den im Kapitel 2.4 eingeführten Kovarianz- und Korrelationsmodellen wird Anisotropie dementsprechend durch das Hinzufügen der zwei oben eingeführten Parameter modelliert: dem Anisotropieverhältnis λ und dem Winkel β der Orientierung.

Abschließend sei angemerkt, dass ein richtungsabhängiges Variogramm nicht *zwangsläufig* durch Anisotropie verursacht sein muss. Auch Verletzungen der Stationaritätsannahme können zu einem ähnlichen Verhalten führen (vgl. z. B. Montero, Fernández-Avilés und Mateau 2015, Kap. 3.7, Kitanidis 1997, Kap. 5).

3 Analyse der Feinstaubdaten

Dieses Kapitel ist wie folgt strukturiert:

- Das Kapitel 3.1 stellt die wesentlichen Informationen rund um das Thema Feinstaub bereit. Hierbei werden die grundlegenden Definitionen eingeführt, die möglichen Feinstaub-Quellen beschrieben und in kompakter Form die Bedeutung von Feinstaub für die menschliche Gesundheit erläutert.
- Im Kapitel 3.2 wird zunächst die Herkunft der für die Analyse herangezogenen Messdaten aufgezeigt und anschließend
- im Kapitel 3.3 deren struktureller Aufbau und die deskriptiv statistischen Charakteristika herausgearbeitet.
- Ein wesentlicher Schritt jeder Datenanalyse ist die Datenbereinigung, die im Kapitel 3.4 beschrieben wird.

3.1 Feinstaub: Definition, Entstehung und Bedeutung für die Gesundheit

Feinstaub bezeichnet feste und flüssige Schwebeteilchen in der Luft, die aufgrund ihrer geringen Größe über längere Zeit in der Atmosphäre verbleiben können.

Unter vereinfachenden Annahmen lässt sich für die Sinkgeschwindigkeit v_s von kugelförmigen Partikeln mit Durchmesser d aus der Stokes-Gleichung eine quadratische Abhängigkeit $v_s \propto d^2$ herleiten (vgl. z. B. Landau und Lifshitz 1987, Kap. 20), was für $d = 2,5 \mu m$ zu Sinkgeschwindigkeiten im Bereich von Zentimetern pro Stunde und dementsprechend langen atmosphärischen Verweildauern führt. Insbesondere besitzen kleinere Partikel wesentlich längere Verweildauern in der Atmosphäre und können daher über größere Entfernungen transportiert werden.




Abbildung 14: Atemwegs-Gängigkeit von Feinstaub⁶

⁶Bild entnommen aus: Leitfaden zur Norm ISO 16890 für Luftfiltration der Firma MANN+HUMMEL

Die von Feinstaub ausgehende Gesundheitsgefährdung hängt maßgeblich davon ab, wie weit dieser über den Atemweg Nase→Hals→Lunge→Blutkreislauf vordringen kann. Diese Atemwegs-Gängigkeit wiederum wird von der Partikelgröße des Feinstaubes bestimmt. Generell gilt: je kleiner die Partikel sind, desto tiefer können sie in die Atemwege und die Lunge eindringen (vgl. Abb. 14).

Mit Blick auf empirisch gestützte Studien, in denen die von Feinstaub ausgehenden Gesundheitsrisiken aufgegriffen wurden, war es zuerst die US-amerikanische Umweltschutzbehörde **Environmental Protection Agency**, welche den Feinstaub in verschiedene Kategorien einteilte:

- Grobstaub: Partikel mit einem Durchmesser d von $d > 10\mu m$;
- PM_{10} : Partikel mit einem Durchmesser d von $d \leq 10\mu m$;
- $PM_{2.5}$: Partikel mit einem Durchmesser d von $d \leq 2,5\mu m$;
- $PM_{0.1}$: Partikel mit einem Durchmesser d von $d \leq 0,1\mu m$ ⁷.

Diese Kategorisierung wurde von der Europäischen Union übernommen und die Bestimmung der PM_{10} und $PM_{2.5}$ Konzentrationen in einer Norm der **International Standardization Organization** festgelegt.

Eine detaillierte Einführung in den Aspekt der Entstehung und der gesundheitlichen Bedeutung von Feinstaub findet sich beispielsweise in den Reports der **World Health Organization** 2021 oder des **Health Effects Institute** 2025, auf die sich die nachfolgenden Ausführungen stützen.

Feinstaub kann einerseits aus natürlichen Vorgängen hervorgehen (z.B. Waldbrände, aufgewirbelten Bodenstaub). Gerade in städtischen Gebieten resultiert der größte Teil der Feinstaubbelastung aus menschlichen Aktivitäten: Reifen- und Bremsabrieb, Verbrennungsprozesse in Motoren, Industrieanlagen sowie Heizungen.

Für die menschliche Gesundheit besitzt Feinstaub eine hohe Bedeutung, da die Partikel über die Atemluft aufgenommen werden. Größere Partikel werden häufig bereits in Nase oder Rachen abgefangen, während kleinere Partikel bis in die Bronchien und Lungenbläschen gelangen können. Ultrafeine Partikel sind sogar in der Lage, die Blutbahn zu erreichen. Langfristig wird Feinstaub mit einem erhöhten Risiko für Herz-Kreislauf-Erkrankungen, chronische Lungenerkrankungen und einer verminderten Lebenserwartung in Verbindung gebracht. Der Report Institute 2025, S. 5 schätzt, dass im Jahr 2023 gesamthaft durch Luftverschmutzung mehr Todesfälle verursacht wurden als durch Tabakkonsum. Aus diesem Grund zählt die Reduzierung von Feinstaubemissionen zu den wichtigen Zielen des Umwelt- und Gesundheitsschutzes.

Das Bayerische Landesamt für Umwelt und das Umwelt-Ressort der Stadt München tragen der großen Bedeutung von Feinstaub für den Umwelt- und Gesundheitsschutz dahingehend Rechnung, dass landesweit mehrere Messstationen unterhalten und überwacht werden (↔ Aktuelle Messwerte der Luftmessstationen), hiervon auch vier Messstationen für Feinstaub (Stand: Juni 2026) im Raum München.

⁷Da Partikel mit einem Durchmesser $d \leq 2,5\mu m$ auch die Bedingung $d \leq 10\mu m$ erfüllen, ist der PM_{10} -Wert stets größer-gleich dem $PM_{2.5}$ -Wert. Analog folgt, dass $PM_{0.1} \leq PM_{2.5}$ gilt.

Die an diesen vier Stationen erhobenen Messwerte sind *nur* als stündliche Mittelwerte verfügbar. Abb. (15) zeigt beispielhaft den Verlauf der PM_{10} - und $PM_{2.5}$ -Messungen an der Messstation am Karlsplatz (Stacchus).




Abbildung 15: Verlauf der Stunden-Mittelwerte der PM_{10} - und $PM_{2.5}$ -Messwerte im April 2026 an der Messstation Karlsplatz (Stacchus) und der festgesetzte Jahresgrenzwert (—)

In Abb. (15) ist zusätzlich der per „Verordnung über Luftqualitätsstandards und Emissionshöchstmengen“ (*kurz*: BImSchV)⁸ festgesetzte Jahresgrenzwert für $PM_{2.5}$ von $25\mu g/m^3$ eingezeichnet (—).

Wie in Kap. 2.3.1 dargelegt, können aus n Messpunkten maximal $n \cdot (n - 1)/2$ paarweise verschiedene Distanzen gebildet werden. Mithilfe der vier vom Bayerischen Landesamt für Umwelt in München unterhaltenen Messstationen ergeben sich daher nur 6 verschiedene Distanzen. Dies ermöglicht keine aussagekräftige Schätzung der Variogramme, so dass in Folge auch keine Kriging-Analyse basierend allein auf diesen Daten möglich ist.

3.2 Herkunft und Qualität der Daten

Untersucht werden Feinstaub-Messungen im Großraum München, die als frei verfügbare Daten über das globale Sensor-Netzwerk SENSORCOMMUNITY (↪ Sensor Community Home) zur Verfügung gestellt werden.

Die auf dem Portal verfügbaren Sensor-Messungen stammen von Nutzern aus über 70

⁸↪ Grenz- und Zielwerte, kritische Werte, Informations- und Alarmschwellen nach der 39. BImSchV

Ländern (Stand 2026) ohne kommerzielle Interessen, welche nach einer einmaligen Registrierung die mittels ihrer *eigenen* Sensoren erhobenen Messdaten auf das Netzwerk hochladen können.

Eine Validierung der von den Nutzern hochgeladenen Daten oder eine Überprüfung der Qualität der verwendeten Sensoren findet *nicht* statt.

Die auf SENSORCOMMUNITY verfügbaren Daten decken die beiden Bereiche

- a) Wetter-Bedingungen, also Temperatur, Luftdruck, Luftfeuchtigkeit und
- b) Feinstaub-Belastung

ab. Darüber hinaus finden sich einige Messdateien der radioaktiven Umgebungsstrahlung und der Lärmentwicklung.

Die historischen Daten sind im Archivbereich ($\leadsto$ Sensor Community Archiv) in einer zeitlich geordneten Struktur in Komma separierten Format als Messdateien abgelegt und werden für unterschiedliche Zeitpunkte für die nachfolgenden Analysen herangezogen.

Um die typische Anzahl der verfügbaren Messungen zu illustrieren und damit die nachfolgenden Überlegungen zu motivieren, seien hier beispielhaft für den 2. April 2026 die Mengenverhältnisse aufgeführt. Im Archiv der SENSORCOMMUNITY sind für diesen Tag

- insgesamt 19796 Messdateien; davon
- 156 Dateien mit zugehörigem Sensor im Großraum München; davon
- 86 Dateien, die Feinstaub-Messungen beinhalten,

verfügbar.

Als Mess-Sensor für die Feinstaub-Messungen kommt der SDS011 ($\leadsto$ SDS011 Datenblatt) zum Einsatz, der für etwa 30 EUR erhältlich ist (Stand Juni 2026). Hierbei handelt es sich um einen Staubsensor, der die Konzentration des Feinstaubes in der Luft über die Beeinflussung der Lichtstreuung einer in den Bausatz integrierten Laserdiode detektiert. Der SDS011 Laser-Staubsensor kann Partikel mit einem Durchmesser von mehr als $0,3\mu m$ erkennen und ist ausgelegt für die größen-fraktionierende Detektion von

- Partikeln mit einem Durchmesser $d \leq 2,5\mu m$ und
- Partikeln mit einem Durchmesser $d \leq 10\mu m$.

Die Messungen erfolgen in der Einheit $\mu g/m^3$ und haben gemäß der Herstellerangabe einen relativen Fehler von 15%. Als mechanisches Bauteil enthält der SDS011 des Weiteren einen Ventilator, der die Umgebungsluft ansaugt und zur Lasereinheit leitet.

Während nach Herstellerangaben der Mess-Sensor SDS011 in der Lage sein sollte, die beiden Feinstaub-Fraktionen PM_{10} und $PM_{2.5}$ zu messen, zeigten sich bei Vergleichsmessungen mit professionellen Feinstaub-Messgeräten unter realen Bedingungen Diskrepanzen (vgl. Clements u. a. 2017, Patwardhan, Sara und Chaudhari 2021): die Messergebnisse des Messsensors SDS011 korrelieren mit den professionell ermittelten PM_x Werte, aber unterschätzen diese tendenziell. Nach den Untersuchungen in Laquai und Saur 2017 fällt diese Abweichung bei den PM_{10} Messwerten größer aus als bei $PM_{2.5}$ Messdaten.

Positiv hingegen fiel in diesen Studien die geringe Variabilität der SDS011 Sensoren auf. Die zuständige Behörde des australischen Bundesstaates New South Wales bezeichnet kostengünstige Feinstaub-Sensoren wie etwa den SDS011 daher als „indicative air quality

instrument“ (vgl. New South-Wales Department of Planning, Industry and Environment 2021).

Da es in dieser Arbeit primär um die *räumliche Analyse* der Daten geht und nicht um deren Interpretierbarkeit im Kontext anderer Studienergebnisse bedeutet diese Messungsgenauigkeit *keine Einschränkung*.

Dennoch, um eventuellen Fehlinterpretationen der im folgenden präsentierten Ergebnisse mit anderen, gemäß der Norm durchgeführten Feinstaub-Messungen vorzubeugen, wird im weiteren Verlauf die Notation P_{10} und $P_{2.5}$ verwendet für Messwerte, die mit dem PM_{10} bzw. $PM_{2.5}$ Messwerte korrelieren.

Die in der Arbeit Patwardhan, Sara und Chaudhari 2021 erwähnte Unterschätzung der professionell ermittelten PM_x durch die SDS011 Mess-Sensoren kann auch beim Vergleich der Datenreihen der vier Messstationen des Landesumweltamtes mit den Messungen von in der Nähe befindlichen SDS011 Sensoren festgestellt werden (vgl. Abb. 16).




Abbildung 16: Vergleich der stündlichen $PM_{2.5}$ Mittelwerte der Messstation an der Landshuter Allee mit den $P_{2.5}$ Mittelwerten von SDS011 Sensoren in rund 500m Entfernung

Es ist deutlich zu erkennen, dass die für eine einstündige Zeitspanne ermittelten $PM_{2.5}$ Mittelwerte (—) der Messstation des Landesumweltamts recht deutlich und durchgängig oberhalb der ebenfalls über eine Stunde gemittelten $P_{2.5}$ Messungen von drei SDS011 Sensoren verlaufen, die in einer Distanz von etwa 500m positioniert sind.

Diese Diskrepanz zeigt sich auch beim Vergleich der übrigen drei vom Landesumweltamt betriebenen Messstationen mit den Daten von in der Nähe befindlichen SDS011 Sensoren,

die durch eine systematische Abweichung der SDS011 Messungen erklärt werden könnte. Erwähnenswert mit Blick auf Abb. (16) ist die geringe Variabilität der drei SDS011 Sensoren untereinander; alle drei Zeitreihen liegen sehr dicht beieinander, was aufgrund ihrer räumlichen Nähe zu erwarten sein sollte (erstes Gesetz der Geografie; vgl. Kap. (2.1)).

3.3 Struktur der Daten

Die Daten sind in den Messdateien im Wide-Format abgelegt, im Einzelnen:

- **sensor_id**: eine natürliche Zahl zur eindeutigen Identifikation des Sensors;
- **sensor_type**: eine Zeichenfolge zur Spezifikation des verwendeten Sensor-Typs; bei den nachfolgend betrachteten Feinstaub-Messungen ist dies ausnahmslos ein Sensor vom Typ SDS011;
- **location**: eine natürliche Zahl die zur Bestimmung der Position des Sensors genutzt werden kann;
- **lat**: die geodätische Breite (Breitengrad, engl. *latitude*) angegeben als Gleitkommazahl zur Bestimmung des Winkels der räumlichen Position gemessen als Winkel zur Äquatorebene;
- **lon**: die geodätische Länge (Längengrad, engl. *longitude*) angegeben als Gleitkommazahl zur Bestimmung des Winkels der räumlichen Position bezogen auf den Nullmeridian (0°);
- **timestamp**: eine Zeichenfolge im Format YYYY-MM-DDThh:mm:ss zur Bestimmung von Jahr (YYYY), Monat (MM), Tag (DD), Stunde (hh), Minute (mm) und Sekunde (ss) der Messung;
- **P1**: der P_{10} Messwert (indikativer PM_{10} Messwert) angegeben in $\mu g/m^3$;
- **durP1**: eine Gleitkommazahl, die bei keiner der Messungen mit dem Sensor SDS011 belegt ist;
- **ratioP1**: eine Gleitkommazahl, die bei keiner der Messungen mit dem Sensor SDS011 belegt ist;
- **P2**: der $P_{2.5}$ Messwert (indikativer $PM_{2.5}$ Messwert) angegeben in $\mu g/m^3$;
- **durP2**: eine Gleitkommazahl, die bei keiner der Messungen mit dem Sensor SDS011 belegt ist;
- **ratioP2**: eine Gleitkommazahl, die bei keiner der Messungen mit dem Sensor SDS011 belegt ist;

Die beiden geodätischen Koordinaten Breitengrad und Längengrad sind hierbei nicht im Sexagesimalsystem, also in Grad ($^\circ$), Minuten ($'$) und Sekunden ($''$) angegeben, sondern als Dezimalgrad mit drei Nachkommastellen. Dies entspricht einer Granularität von 111m (vgl. z. B. $\rightsquigarrow$ Wikipedia: Genauigkeit von Koordinaten).

In Tab. (1) ist beispielhaft für eine Messreihe vom 2. April 2026 die Struktur-Analyse aufgeführt. Hierbei fällt mit Blick auf die Zähl-Spalte der NA-Werte (3. Spalte) auf, dass für alle der insgesamt 569 Messungen an diesem Tag die Einträge **durP1**, **ratioP1**, **durP2**, **ratioP2** nicht belegt sind. Diese vier Größen werden daher nachfolgend nicht weiter betrachtet.

Die Spannweite (engl. *span*) gibt die obere und untere Grenze (gleichsam das kleinste und

größte der Quartile) des beobachteten Intervalls der Messgröße an. In Tab. (1) erfolgt die Angabe des Modus (engl. *mode*) im Format häufigster Wert und in Klammern dahinter, wie oft dieser Wert beobachtet wurde. Die Anzahl der verschiedenen beobachteten Werte ist in der Spalte „#Classes“ wiedergegeben. Für metrisch skalierte Variablen sind der arithmetische Mittelwert (engl. *mean*) und Median (engl. *median*) angegeben.

Column	Type	#NA	Mean	Median	Span	Mode	#Classes
sensor_id	int	0	6117	6117	[6117,6117]	6117 (569)	1
sensor_type	string	0	nan	nan	[nan,nan]	SDS011 (569)	1
location	int	0	3089	3089	[3089,3089]	3089 (569)	1
lat	float	0	48.20	48.20	[48.20,48.20]	48.20 (569)	1
lon	float	0	11.51	11.51	[11.51,11.51]	11.51 (569)	1
timestamp	string	0	nan	nan	[nan,nan]	2026-04... (1)	569
P1	float	0	10.64	10.27	[5,20]	9.80 (9)	237
durP1	float	569	nan	nan	[nan,nan]	nan (569)	1
ratioP1	float	569	nan	nan	[nan,nan]	nan (569)	1
P2	float	0	5.01	4.9	[3,8]	4.80 (15)	120
durP2	float	569	nan	nan	[nan,nan]	nan (569)	1
ratioP2	float	569	nan	nan	[nan,nan]	nan (569)	1

Tabelle 1: Statistische Struktur-Analyse beispielhaft für die Datenreihe eines SDS011 Sensor vom 2. April 2026. „nan“ (engl. *not a number*) bezeichnet nicht verfügbare Angaben.

Die Häufigkeits-Analyse der P_{10} -Messwerte desselben Sensors für den 2. April 2026 ist in Abb. (17) wiedergegeben.




Abbildung 17: Häufigkeits-Analyse der P_{10} Messwerte des SDS011 Sensors (ID 6117)

Hier bestätigt das erkennbar links-steile Histogramm die aus dem Vergleich von Median und arithmetischen Mittelwert der Tab. (1) genährte Vermutung einer nicht symmetrischen Verteilung der Messwerte.

Das Histogramm der $P_{2.5}$ -Messwerte zeichnet für diesen Sensor qualitativ das gleiche Bild.

3.4 Datenbereinigung

Die pro Tag für den Großraum München verfügbaren Datenreihen unterschiedlicher Sensoren und damit unterschiedlicher räumlicher Position weisen eine stark heterogene Qualität auf. Aufgrund der pro Tag mit 80-100 Dateien (vgl. Kap. 3.2) eher geringen Anzahl von Feinstaub-Messungen ist es ratsam, möglichst viele der Dateien nach einer eventuellen Datenbereinigung für die weiteren Analysen verwenden zu können und so wenig wie möglich Dateien zu verwerfen.

Die Messreihen der unterschiedlichen Sensoren lassen sich hinsichtlich Qualität grob in fünf Kategorien einteilen:

- die Messreihen weisen größere zeitliche Unterbrechungen auf;
- die Messreihen weisen NA-Werte auf;
- die Messreihen weisen im Vergleich zu Messreihen der übrigen Sensoren auffallend wenige verschiedene Messwerte auf;
- die Messreihen weisen für den $PM_{2.5}$ - und/oder den PM_{10} -Messwert *aufeinanderfolgend* hohe Werte auf, die oberhalb der gesetzlichen Grenzwerte liegen;
- die Messreihen sind von guter Qualität.




Abbildung 18: Verlauf der P_{10} Messwerte eines Sensors am 2. April 2026. Etwa zwischen 10 und 14 Uhr gab es eine Sequenz der Länge 92 von Messwerten zwischen $600 - 1100 \mu\text{g}/\text{m}^3$ und damit deutlich oberhalb des Schwellwertes (—)

Abb. (18) zeigt ein Beispiel der Kategorie d), Abb. (19) ein Beispiel der Kategorie a).




Abbildung 19: Verlauf der P_{10} Messwerte eines Sensors am 24. April 2026. Etwa von 9 bis 11 Uhr gab es eine Unterbrechung der Mess-Aufzeichnung von insgesamt 103 Minuten Dauer

In beiden Abbildungen sind neben den Messwerten (•), noch der zentrierte gleitende Durchschnitt (—) und das Toleranzband (■) eingezeichnet. Hierbei wird das Toleranzband durch das Intervall [gleitender Durchschnitt $\pm 2 \cdot$ Standardabweichung der Messreihe] definiert und dient wie auch der gleitende Durchschnitt ausschließlich der visuellen Erkennung von eventuellen Auffälligkeiten der Messreihe.

Mit Messreihen der Kategorien a) bis d) wurde folgendermaßen verfahren:

- Messreihen mit Unterbrechungen der Mess-Aufzeichnung von mehr als 180 Minuten Länge wurden für die weiteren Analysen *nicht* berücksichtigt.
- Bei den Messdateien, in denen NA-Werte auftraten, handelt es sich um zeilenweise erratisch eingefügte Messungen mit einer validen Zeitangabe aber fehlenden Messwerten. Nach der Entfernung dieser fehlerhaften Zeilen war die verbleibende Messreihe unauffällig und wurde für die weiteren Auswertungen verwendet.
- Messreihen, die weniger als 20 verschiedene Messwerte pro Tag aufweisen, wurden *nicht* weiter berücksichtigt. Vermutlich handelt es sich hier um einen Defekt oder eine Fehlkonfiguration des D/A-Wandlers des SDS011 Sensors.
- Messreihen, bei denen mehr als 120 *nacheinander folgende* Messwerte (Definition einer Sequenz der Länge 120) oberhalb eines Schwellwertes von $100 \mu g/m^3$ liegen, wurden *nicht* weiter berücksichtigt. Andernfalls hätten solche Messungen die anschließend durchgeführten Mittelwertbildungen und die darauf aufsetzenden Auswertungen stark verzerrt.

Für die getroffenen Festsetzungen gibt es keine wissenschaftliche Rechtfertigung; sie sind das Ergebnis einer Abwägung der antagonistischen Ziele einer möglichst großen Datenbasis einerseits und einer guten Datenqualität andererseits.

Durch diese Schritte der Datenbereinigung der täglichen Messdaten wurde die Anzahl der im weiteren Verlauf betrachteten, täglichen Messreihen um etwa 2-4 Stück, also grob weniger als 5% verkleinert.

Nach Abschluss der reproduzierbaren Datenbereinigung liegt nunmehr ein konsistenter Datensatz vor, der im folgenden Kapitel zur Untersuchung der räumlichen Abhängigkeitsstruktur verwendet wird.

4 Datenauswertung

4.0.1 Kriging Interpolation mit anisotropen Kovarianz-Modellen

Wie im vorherigen Kapitel ?? ausgeführt, lässt sich auf der Grundlage der vorhandenen Messungen keine belastbare Aussage hinsichtlich einer möglichen Anisotropie der Feinstaubdaten treffen.

Die in diesem Kapitel vorgestellte Methode versteht sich als ein explorativer Ansatz, um *Indizien* für oder gegen die Anisotropie-Vermutung herauszuarbeiten. Zu diesem Zweck wird das folgende Vorgehen durchgeführt::

- 1) bei schrittweiser Variation der Anisotropie mit $\Delta\lambda = 1$, wobei $1.5 \leq \lambda \leq 3.5$, sowie
- 2) mit einer Schrittweite des Sill von $\Delta S = 2$, wobei $2 \leq S \leq 6$, und
- 3) mit einer Winkel-Schrittweite von $\Delta\vartheta = 20^\circ$, wobei $0^\circ \leq \vartheta < 360^\circ$
- 4) wird ein anisotropes Kovarianz-Modell definiert und damit für die beobachteten Werten die Kriging-Gleichungen gelöst. Insbesondere findet somit *keine* Anpassung der Modell-Parameter an die richtungsabhängig geschätzte Semivarianz statt, da sich hierbei -wie in Kapitel ?? ausgeführt- ja keine verwertbaren Ergebnisse zeigen.
- 5) Um die Güte der anisotropen Modell-Wahl zu evaluieren, wird ein Leave-One-Out Cross-Validation (*kurz*: LOO-CV) Ansatz (vgl. z. B. Murphy 2023, Kap. 3.8.4) gewählt:
 - a) Aus den n Beobachtungen werden $(n - 1)$ ausgewählt und mit deren Hilfe die Kriging-Gewichte bestimmt.
 - b) Für die eine, noch nicht verwendete Beobachtung wird eine Vorhersage erzeugt und für diese die quadrierte Differenz e_j zur Beobachtung berechnet.
 - c) Dieser Ablauf wird für alle n möglichen Aufteilungen in Training- und Test-Menge durchgeführt.
 - d) Damit berechnet sich der Fehler e_{MSE} der Cross-Validation:

$$e_{\text{MSE}} = \frac{1}{n} \sum_{j=1}^n e_j.$$

Da die Parameter des anisotropen Kovarianz-Modells *nicht* mithilfe der empirischen Semivarianz anhand der Messdaten geschätzt werden können, ist das skizzierte Vorgehen methodisch eher als eine Art plausibilisiertes Raten zu bezeichnen und stellt sicher *keine* saubere Analyse dar.

Es erweist sich, dass die Standardabweichung der von e_{MSE} typischerweise um einen Faktor 4–5 größer ist, als e_{MSE} selber: die einzelnen Werte der $\{e_j\}_{j \in [n]}$ decken typischerweise eine Spannbreite von 8 – 16 Größenordnungen ab, wobei die größten Werte genau dann auftreten, wenn für ungewöhnlich große Beobachtungen der Feinstaub-Konzentration eine Vorhersage gemäß Schritt b) bestimmt wird und die Menge der korrespondierenden Trainingsdaten nach a) überwiegend sehr viel kleinere Feinstaub-Werte beinhaltet. Diese nur wenigen, aber sehr großen Wert e_j ziehen den als Mittelwert kalkulierten Fehler e_{MSE} nach oben und führen zu den großen Schwankungen gegeben durch die Standardabweichung.

Die Ergebnisse dieser Analyse für den November 2025 sind für ein festes Anisotropie-Verhältnis bzw. einen festen Sill in den Abb. (20) und (21) wiedergegeben.




Abbildung 20: Ergebnis der Leave-One-Out Cross-Validation für ein fixes Anisotropie-Verhältnis von $\lambda = 3.5$ basierend auf den gemittelten $P_{2.5}$ -Messwerten für November 2025




Abbildung 21: Ergebnis der Leave-One-Out Cross-Validation für einen fixen Sill von $S = 4.0$ basierend auf den gemittelten $P_{2.5}$ -Messwerten für November 2025

Da nur das Anisotropie-Verhältnis λ variiert wird, muss für eine der beiden Halbachsen der Ellipse ein Wert vorgegeben werden. Hierfür wurde die kleine Halbachse für alle drei Sätze der monatlich gemittelten Messungen auf den maximalen Wert der paarweisen euklidischen Distanz R_{max} der Sensoren-Positionen gesetzt. Dies hat zur Folge, dass die

Werte der großen Halbachse $\lambda \cdot R_{max}$ im Bereich von etwa 30 – 60 km liegen.

Aus beiden Abbildungen ersieht man:

- den geringsten Prognosefehler e_{MSE} weisen die konstruierten anisotropen Kovarianz-Modell auf, die eine Drehung der Koordinaten in Richtung 40° (oder gleichbedeutend 220°) beinhalten. Diese Beobachtung ist unabhängig vom gewählten Wert für Anisotropie und Sill.
- Tendenziell verringert sich mit steigender Anisotropie der Fehler e_{MSE} .
- Tendenziell verringert sich mit abnehmendem Sill der Fehler e_{MSE} .

Auch die analogen Auswertungen der Messungen aus dem Juli 2025 in Abb. (22) und dem April 2026 in Abb. (23) weisen den geringsten Prognose-Fehler für das Kovarianz-Modell auf, welches eine Drehung um etwa 40° bzw. 20° impliziert.

Hierbei sind diese Vorzugsrichtungen wiederum unabhängig vom gewählten Wert für Anisotropie und Sill.




Abbildung 22: Ergebnis der Leave-One-Out Cross-Validation für ein fixes Anisotropie-Verhältnis von $\lambda = 3.5$ basierend auf den gemittelten $P_{2.5}$ -Messwerten für Juli 2025




Abbildung 23: Ergebnis der Leave-One-Out Cross-Validation für ein fixes Anisotropieverhältnis von $\lambda = 3.5$ basierend auf den gemittelten $P_{2.5}$ -Messwerten für April 2026

Der Vollständigkeit halber sind in Abb. (24) und (25) die Visualisierungen von Erwartungswert und Varianz der Kriging-Interpolation für ein konstruiertes, anisotropes Kovarianz-Modell mit ($\vartheta = 40^\circ$, $\lambda = 3.5$) dargestellt.




Abbildung 24: Erwartungswert der Kriging-Interpolation für $\vartheta = 40^\circ$, $\lambda = 3.5$ und $S = 0.8$ basierend auf den gemittelten $P_{2.5}$ -Messwerten für November 2025




Abbildung 25: Varianz der Kriging-Interpolation für $\vartheta = 40^\circ$, $\lambda = 3.5$ und $S = 0.8$ basierend auf den gemittelten $P_{2.5}$ -Messwerten für November 2025

Die Anisotropie des zugrundeliegenden Kovarianz-Modells erkennt man in Abb. (24) recht deutlich in der oberen linken Ecke anhand der ellipsoiden, rot gefärbten Flächen.

4.1 Verwandte Arbeiten

Es existieren themenverwandte Arbeiten, die überwiegend aber eine andere Zielsetzung verfolgen:

- In der Arbeit Kim u. a. 2014 werden die jährlichen Mittelwerte der PM_{10} Konzentration in koreanischen Großstädten mittels ordinary Kriging untersucht. Insgesamt werden 226 Messstationen untersucht. Die durch Schätzung der empirischen Semivarianz ermittelten Werte für den Range schwanken zwischen 8.8 km für Seoul und 29.5 km für das gesamte untersuchte Areal. Die Autoren konstatieren schlechte Resultate basierend auf Methode und Datenlage.
- In der Arbeit Jang 2023 werden die jährlichen Mittelwerte der $PM_{2.5}$ Konzentration in Taiwan mithilfe des in dieser Arbeit nicht beschriebenen multivariaten Indikator Kriging untersucht. In jener Arbeit werden für die Jahre 2019-2021 Ranges zwischen $30 - 50\text{ km}$ und für die Jahre 2020-2022 Ranges von $20 - 60\text{ km}$ ermittelt. Die von den Autoren ermittelte Spannbreite für den Range unterstützt die Feststellung, dass der Range im Rahmen dieser Arbeit prinzipiell gar nicht schätzbar wäre, weil die maximale paarweise Distanz der untersuchten Sensoren zu gering ist.
- In der Arbeit Shukla u. a. 2020 werden die monatlichen und jährlichen Mittelwerte der $PM_{2.5}$ Konzentration von rund 30 Messstationen innerhalb der indischen Stadt Delhi mithilfe des ordinary Kriging und des in dieser Arbeit nicht beschriebenen Methode des Inverse Distant Weighting vergleichend untersucht. In jener Studie liefern beide Methoden vergleichbare Ergebnisse. Die Autoren merken an, dass die für die Anwendung des Kriging wichtige Voraussetzung der Stationarität möglicherweise nicht erfüllt sein könnte.

- In der Arbeit Ramos u. a. 2016 werden die täglichen Mittelwerte der $PM_{2.5}$ Konzentration auf der kanadischen Insel Montreal mithilfe der Methoden des Inverse Distance Weighting und dem Kriging mit externem Drift untersucht. Der Fokus jener Arbeit liegt auf einer möglichst guten raum-zeitlichen Vorhersage der $PM_{2.5}$ Konzentrationen und favorisiert hierfür ein hybrides Modell aus Inverse Distance Weighting und Kriging mit Drift unter Einbeziehung von Kovariablen. Für jene Untersuchung werden die Messungen von rund 10 Stationen herangezogen.

5 Diskussion und Ausblick

Zielsetzung dieser Arbeit war die Untersuchung, ob die betrachteten Feinstaubmessungen Hinweise auf eine räumliche Anisotropie liefern und ob sich diese bei der Modellierung mittels Kriging berücksichtigen lässt.

Die Untersuchungen in dieser Arbeit liefern Indizien für das Vorliegen einer anisotropen Verteilung der Feinstaub-Messungen in der Stadt München aber keinen nach wissenschaftlichen Maßstäben haltbaren Beweis. Insbesondere kann die Frage nach dem Vorliegen einer geometrischen oder zonalen Anisotropie nicht geklärt werden.

Die Ergebnisse des Kriging unter der Anisotropie-Annahme liefern plausible Ergebnisse.

Die Variogramm-Karten für den Range als Standard-Methode zur Detektion von räumlicher Anisotropie liefern unplausible Ergebnisse: der Range wird mittels einer restringierten numerischen Anpassung an ein theoretisches Kovarianz-Modell bestimmt, wobei der Range-Parameter nach oben durch die maximale, paarweise Distanz der untersuchten Sensoren beschränkt ist, die bei etwa $21 - 24 \text{ km}$ liegt.

Da die Schätzungen der empirischen Semivarianz vielfach nicht die zu erwartende Sättigung in das Sill-Plateau bei großen Werten des Lag aufweisen (vgl. z. B. Abb. (??)) kommt es bei der Anpassung zu numerischen Artefakten: der Range der Anpassung wird als die maximale, paarweise Distanz geschätzt.

Für den Sill als einem weiteren Parameter der numerischen Anpassung gibt es keine vorgegebene Beschränkung des Fit-Intervalls. Interessanterweise zeigen die Variogramm-Karten für den Sill eine bevorzugte Richtung, in der der Sill deutlich höhere Werte annimmt als in einer senkrecht dazu stehenden Richtung. Das ist kein stringenter Beweis für eine räumliche Anisotropie der Daten, könnte aber ein Indiz sein: Sill und Range charakterisieren als y - und x -Koordinate denselben ausgezeichneten Punkt des Übergangs vom ansteigenden Ast hin zum Plateau, welches den Bereich der räumlichen Unkorreliertheit der Zufallsvariablen einleitet. Dieser Zusammenhang führt zu einer Korrelation beider Parameter, solange die Beobachtungen im ansteigenden Ast der Semivarianz liegen.

Im letzten Teil der Arbeit werden Kriging-Vorhersagen für anisotrop konstruierte Kovarianz-Modelle betrachtet, deren Parametrisierungen mit den vorherigen Beobachtungen konsistent sind. Diese mithilfe einer Leave-One-Out Cross-Validation durchgeführten Analysen weisen auf eine ausgezeichnete Richtung hin, welche in allen drei Sätzen der gemittelten Messungen gesehen wird. Die Aussagekraft dieser Analyse ist aufgrund der beschriebenen Einschränkungen und der hohen Varianz der ermittelten Werte begrenzt.

Geometrische Besonderheiten der Sensor-Positionen?

Folglich wurden Ursachen dieser möglichen Anisotropie systematisch *nicht* weiter untersucht. Ein paar erste Vermutungen lassen sich aber anstellen: auf Grundlage der vorliegenden Daten erscheint eine Erklärung anhand einer vorherrschenden Windrichtung wenig plausibel: die betrachteten Datensätze beschreiben die monatlichen Mittelwerte von Sensoren, welche eine Fläche von überschlägig $20 \text{ km} \cdot 15 \text{ km} = 300 \text{ km}^2$ abdecken und darüber hinaus noch unterschiedlichen Jahreszeiten zuzuordnen sind.

Wahrscheinlicher erscheinen zeitlich unveränderliche bauliche oder vegetative Gegebenheiten als mögliche Erklärung.

Zusammenfassend sprechen die Ergebnisse dafür, dass anisotrope Modelle bei der räumlichen Analyse der betrachteten Feinstaubdaten eine sinnvolle Erweiterung isotroper Modelle darstellen können. Für eine belastbare Bestätigung wären jedoch umfangreichere Datensätze und weiterführende Untersuchungen erforderlich.

Als weitere Untersuchungen würden sich anbieten:

- Untersuchung eines größeren Untersuchungsgebietes bei vergleichbarer Sensordichte.
- Die Betrachtung deutlich längerer Zeiträume, wie sie in verwandten Arbeiten durchgeführt wurde, könnte ebenfalls die Aussagekraft der Analysen deutlich erhöhen.
- Da die Messdaten nicht normal-verteilt sind, wäre es aufschlussreich, die Auswirkungen einer vorherigen Transformation der schiefen Daten zu testen.
- Die Untersuchung möglicher saisonaler Einflüsse ist ein guter Einstieg in eine möglicherweise noch detailliertere raum-zeitliche Modellierung der Feinstaubdaten.
- Die Verwendung der Kriging Methode mit externem Drift (universal Kriging) in Kombination mit anisotropen Kovarianz-Modellen wäre eine weitere vielversprechenden Analyse.

A Anhang

A.1 Weitere Kovarianz-Funktionen

o Stable Modell

$$\rho_{stb}(r; \ell) := \exp\left(-\left(\frac{r}{\ell}\right)^\alpha\right), \quad \alpha \in (0, 2], \quad (33)$$

wobei $\ell \in \mathbb{R}_+ \setminus \{0\}$.




Abbildung 26: Korrelations-Funktion des stabilen Modells für verschiedene Parameter ℓ




Abbildung 27: Realisierung eines isotropen, schwach stationären Gauß'schen Zufallsfelds mit stabilem Modell (links) und das zugehörige Korrelogramm (rechts)

Das Stable Modell spezifiziert wiederum eine ganze Modell Familie. Insbesondere gilt (vgl. z. B. Montero, Fernández-Avilés und Mateau 2015, S. 25):

- für $\alpha = 1$ entspricht das Stable Modell dem exponentiellen Modell;
- für $\alpha = 2$ entspricht das Stable Modell dem Gauß'schen Modell.

◦ Gauß'sches Modell

$$\rho_{gau}(r; \ell) := \exp\left(-\frac{r^2}{\ell^2}\right), \quad \ell \in \mathbb{R}_+ \setminus \{0\} \quad (34)$$




Abbildung 28: Korrelations-Funktion des Gauß'schen Modells für verschiedene Parameter ℓ




Abbildung 29: Realisierung eines isotropen, schwach stationären Gauß'schen Zufallsfelds mit Gauß'schen Modell (links) und das zugehörige Korrelogramm (rechts)

○ Matérn Modell

$$\rho_{mat}(r; \ell, \nu) := \frac{1}{\Gamma(\nu)2^{\nu-1}} \left(\frac{\sqrt{2\nu}}{\ell} r \right)^\nu K_\nu \left(\frac{\sqrt{2\nu}}{\ell} r \right), \quad (35)$$

wobei

- $\Gamma(\cdot)$ die Gamma-Funktion,
- $K_\nu(\cdot)$ die hyperbolische Bessel-Funktion zweiter Art $\rightsquigarrow$ Wiki: Bessel function
- $\ell, \nu \in \mathbb{R}_+ \setminus \{0\}$ Modell-Parameter

bezeichnen.




 Abbildung 30: Korrelations-Funktion des Matérn-Modells für verschiedene Parameter ℓ


Abbildung 31: Realisierung eines isotropen, schwach stationären Gauß'schen Zufallsfelds mit Matérn Modell (links) und das zugehörige Korrelogramm (rechts)

Im Limes $\nu \rightarrow \infty$ konvergiert das Matérn Modell gegen das Gauß'sche Modell, das heißt, das Gauß'sche Modell ist Teil der Matérn Modell Familie (vgl. z. B. Rasmussen und Williams 2006, S. 84f).

A.2 Ergänzende Analysen der Datenauswertung




Abbildung 32: Anpassung der Kovarianz-Funktion (—) an die directionale ($\vartheta = 340^\circ$) empirische Semivarianz (●); oberhalb der empirischen Semivarianz sind die Umfänge des Lags vermerkt; der obere Wert der Beschränkung für den Range beträgt 100 km




Abbildung 33: Directionale Variogramm-Karte für den Range basierend auf den gemittelten $P_{2.5}$ -Messwerten für April 2026; der obere Wert der Beschränkung für den Range beträgt 100 km




Abbildung 34: Direktionale Variogramm-Karte für den Sill basierend auf den gemittelten $P_{2.5}$ -Messwerten für April 2026 (links) und Juli 2025 (rechts)

A.3 Unterstützung durch Künstliche Intelligenz

*... Oh, I get by with a little help from my friends
Mm, I'm gonna try with a little help from my friends
Ooh, I get high with a little help from my friends ...*

The Beatles, „With a little help from my friends“

Die vorliegende Arbeit wurde in deutscher Sprache geschrieben und anschließend mit Hilfe der Programme **ChatGPT** und **Claude** hinsichtlich Interpunktion und Orthografie überprüft und anhand der Korrekturvorschläge teilweise händisch überarbeitet.

Sehr inspirierend waren auch die vielen Chats mit **Claude** hinsichtlich der Optimierung von Grafiken. Hier sind viele der von **Claude** ausgehende Impulse in die Ausgestaltung der Abbildungen eingeflossen. Erstellt habe ich die Grafiken allerdings ausnahmslos selbstständig.

B Elektronischer Anhang

Daten, Programm-Code and die gezeigten Bilder sind in elektronischer Form hier verfügbar
↪ GitHub Public Repo

C Literaturverzeichnis

- Adler, Robert J. Adler und Jonathan E. Taylor (2007). *Random Fields and Geometry*. Springer Verlag.
- Benndorf, Jörg (2023). *Angewandte Geodatenanalyse und -Modellierung*. Springer Vieweg.
- Carrasco, P. C. (2010). “Nugget effect, artificial or natural?” In: *Journal of the Southern African Institute of Mining and Metallurgy* 110.6, S. 299–305.
- Chiles, Jean-Paul und Pierre Delfiner (1999). *Geostatistics Modeling Spatial Uncertainty*. John Wiley & Sons.
- Clements, Andrea L. u. a. (2017). “Low-Cost Air Quality Monitoring Tools: From Research to Practice (A Workshop Summary)”. In: *Sensors* 11, S. 2478.
- Cressie, Noel und Douglas M. Hawkins (1980). “Robust Estimation of the Variogram: I”. In: *Journal of the International Association for Mathematical Geology* 12.2, S. 115–125.
- Cressie, Noel A. C. (1993). *Statistics for Spatial Data*. John Wiley & Sons.
- Diggle, Peter J. und Paulo J. Jr. Ribeiro (2007). *Model-based Geostatistics*. Springer Verlag.
- Dowd, P. A. (1984). “The Variogram and Kriging: Robust and Resistant Estimators”. In: *Geostatistics for Natural Resources Characterization: Part 1*. Hrsg. von Georges Verly u. a. Springer Netherlands, S. 91–106.
- Forster, Otto (2017). *Analysis* 3. 8. Aufl. Springer Verlag.
- Genton, M. G. (Feb. 1998). “Highly Robust Variogram Estimation”. In: *Journal of Mathematical Geology* 94, S. 213–221.
- Haynes, William M., Hrsg. (2017). *CRC Handbook of Chemistry and Physics*. 97. Aufl. CRC Press.
- Henze, Norbert (2019). *Stochastik: Eine Einführung mit Grundzügen der Maßtheorie*. Springer Verlag.
- Institute, Health Effects (2025). *State of Global Air: Report on Air Pollution and its Role in the Worlds Leading Causes of Death*. Techn. Ber. Boston, MA, USA. URL: <https://www.stateofglobalair.org/resources/report/state-global-air-report-2025>.
- Jang, Cheng-Shin (2023). “Probabilistic assessment of spatiotemporal fine particulate matter concentrations in Taiwan using multivariate indicator kriging”. In: *Stochastic Environmental Research and Risk Assessment* 38, S. 761–776.
- Journel, A. G. und Ch. J. Huijbregts (1989). *Mining Geostatistics*. 4. Aufl. Academic Press Limited.
- Kim, Sun-Young u. a. (2014). “Ordinary kriging approach to predicting long-term particulate matter concentrations in seven major Korean cities”. In: *Environmental Health and Toxicology* 29.
- Kitanidis, P. K. (1997). *Introduction to Geostatistics: Application to Hydrogeology*. Cambridge University Press.
- Krige, Danie Gerhardus (Dez. 1951). “Statistical Approach to Some Basic Mine Valuation Problems on the Witwatersrand”. In: *Journal of the Chemical, Metallurgical and Mining Society of South Africa* 6, S. 119–139.

- Kroese, Dirk P. und Zdravko I. Botev (2015). “Spatial Process Simulation”. In: *Stochastic Geometry, Spatial Statistics and Random Fields*. Hrsg. von Volker Schmidt. Springer International Publishing, S. 369–404.
- Landau, Lew Dawidowitsch und Jewgeni Michailowitsch Lifshitz (1987). *Fluid Mechanics*. 2. Aufl. Pergamon Press.
- Laquai, Bernd und Antonia Saur (Dez. 2017). “Development of a Calibration Methodology for the SDS011 Low-Cost PM-Sensor with respect to Professional Reference Instrumentation”. ResearchGate. URL: https://www.researchgate.net/publication/322628807_Development_of_a_Calibration_Methodology_for_the_SDS011_Low-Cost_PM-Sensor_with_respect_to_Professional_Reference_Instrumentation.
- Matheron, Georges (Dez. 1963). “Principles of Geostatistics”. In: *Journal of Economic Geology* 58.8, S. 1246–1266.
- (1971). *The Theory of Regionalised Variables and its Applications*. École National Supérieure des Mines.
- Meintrup, David und Stefan Schäffler (2005). *Stochastik - Theorie und Anwendungen*. Springer Verlag.
- Miller, Harvey J. (2004). “Tobler’s First Law and Spatial Analysis”. In: *Annals of the Association of American Geographers* 94.2, S. 284–289.
- Montero, José-María, Gema Fernández-Avilés und Jorge Mateau (2015). *Spatial and Spatio-Temporal Geostatistical Modeling and Kriging*. John Wiley & Sons.
- Murphy, Kevin P. (2023). *Probabilistic Machine Learning: Advanced Topics*. The MIT Press.
- New South-Wales Department of Planning, Industry and Environment (2021). *Indicative Air Quality Instrument Evaluation*. Techn. Ber. URL: <https://www.environment.nsw.gov.au/sites/default/files/indicative-air-quality-instrument-evaluation-210537.pdf>.
- Oliver, Margaret A. und Richard Webster (2015). *Basic Steps in Geostatistics: The Variogram and Kriging*. Springer Verlag.
- Organization, World Health (2021). *WHO global air quality guidelines. Particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. Techn. Ber. Geneva, Switzerland. URL: <https://iris.who.int/server/api/core/bitstreams/551b515e-2a32-4e1a-a58c-cdaecd395b19/content>.
- Patwardhan, Ishan, Spanddhana Sara und Sachin Chaudhari (Aug. 2021). “Comparative Evaluation of New Low-Cost Particulate Matter Sensors”. In: *8th International Conference on Future Internet of Things and Cloud (FiCloud)*, S. 192–197.
- Ramos, Yuddy u. a. (2016). “Spatio-temporal models to estimate daily concentrations of fine particulate matter in Montreal: Kriging with external drift and inverse distance-weighted approaches”. In: *Journal of Exposure Science and Environmental Epidemiology* 26.4, S. 405–414.
- Rasmussen, Carl Edward und Christopher K. I. Williams (2006). *Gaussian Processes for Machine Learning*. The MIT Press.
- Schmid, Volker und Nurzhan Sapargali (Jan. 2026). “Spatial Statistics”. Vorlesungs-Skript (unveröffentlicht), Ludwig-Maximilians-Universität München.
- Schmidt, Klaus D. (2011). *Maß und Wahrscheinlichkeit*. 2. Aufl. Springer Verlag.

- Shukla, Komal u. a. (2020). “Mapping spatial distribution of particulate matter using Kriging and Inverse Distance Weighting at supersites of megacity Delhi”. In: *Sustainable Cities and Society* 54, S. 101997.
- Spodarev, Evgeny, Elena Shmileva und Stefan Roth (2015). “Extrapolation of Stationary Random Fields”. In: *Stochastic Geometry, Spatial Statistics and Random Fields*. Hrsg. von Volker Schmidt. Springer International Publishing, S. 321–367.
- Tobler, W. R. (1970). “A Computer Movie Simulating Urban Growth in the Detroit Region”. In: *Economic Geography* 46, S. 234–240.
- Webster, Richard und Margaret A. Oliver (2007). *Geostatistics for Environmental Scientists*. 2. Aufl. John Wiley & Sons.

Declaration of authorship

I hereby declare that the thesis submitted is my own unaided work. All direct or indirect sources used are acknowledged as references. I am aware that the Thesis in digital form can be examined for the use of unauthorized aid and in order to determine whether the report as a whole or parts incorporated in it may be deemed as plagiarism. For the comparison of my work with existing sources I agree that it shall be entered in a database where it shall also remain after examination, to enable comparison with future Theses submitted. Further rights of reproduction and usage, however, are not granted here. This paper was not previously presented to another examination board and has not been published.

Location, date

Name